北京師範大學

专业硕士研究生
学位论文

基于领域预训练视觉大模型的
海洋浮游生物识别研究

作　　者：范胤杰
导　　师：谢传龙
培养单位：北京师范大学
学　　号：202322011011
学科专业：应用统计
完成日期：2025 年 5 月 10 日

北京师范大学学位论文原创性声明

本人郑重声明： 所呈交的学位论文，是本人在导师的指导下，独立进行研究工作所取得的成果。除文中已经注明引用的内容外，本论文不含任何其他个人或集体已经发表或撰写过的作品成果。对本文的研究做出重要贡献的个人和集体，均已在文中以明确方式标明。本人完全意识到本声明的法律结果由本人承担。

学位论文作者签名： 日期： 年 月 日

学位论文使用授权书

学位论文作者完全了解北京师范大学有关保留和使用学位论文的规定，即：学校有权保留并向国家有关部门或机构送交论文的复印件和电子版，允许学位论文被查阅和借阅；学校可以公布学位论文的全部或部分内容，可以允许采用影印、缩印或其它复制手段保存、汇编学位论文。保密的学位论文在解密后适用于本授权书。

本人签名：_____ 日期：_____

导师签名：_____ 日期：_____

基于领域预训练视觉大模型的海洋浮游生物识别研究

摘　要

浮游生物作为水生生态系统的基础组成部分，其监测与分析对生态健康评估、气候变化预警及生物多样性保护具有关键意义。传统浮游生物图像识别方法受限于卷积神经网络模型的参数容量与特征表示能力，难以应对真实海洋环境中的长尾分布、数据集偏移及分布外检测等复杂挑战。在已有的研究工作中，目前没有在海洋浮游生物识别领域充分挖掘现有的深度学习技术的应用潜力，尤其是缺少视觉大模型在该领域的成功应用经验。针对浮游生物图像数据的特殊性和分类学复杂性，本文系统性地探索了基于视觉大模型的浮游生物图像识别方法，涵盖上游领域预训练、下游闭集分类与开集识别等全链路任务，为海洋生态智能监测提供了新的解决方案。

本项研究以 ViT、Swin Transformer、ConvNeXtV2 等视觉大模型为核心，结合掩码图像建模方法，在私有的大规模无标注浮游生物图像数据集上进行领域预训练，并通过 DYB-PLANKTONNET 标注数据集验证预训练视觉大模型在下游任务中的性能。实验表明，视觉大模型可结合领域预训练优化其参数初始化分布，充分提高特征空间的类内紧致性与类间可分性，从而显著提升闭集分类准确率与开集识别鲁棒性。例如，基于 MILAN 预训练的 ViT-Base 模型在闭集分类任务中准确率达 96.40%，较 ResNet50 基线提升 1.59%；Swin-Large 模型在开集识别任务中 AUROC 可达 92.36%，且 FPR95 降至 43.07%，较已有最前沿方法相对效果提升超 40%。这些结果揭示了视觉大模型通过高维特征空间与层次化语义建模，结合领域预训练的先验知识，有效缓解了现有方法中预测精度不足且开集识别表现不稳定的缺点，从而能够在动态海洋环境中能够保持稳定的泛化性能。同时，本研究利用自监督预训练方案解决了该领域传统方法对标注训练样本的强依赖性，将海量无标注数据转化为表征学习的驱动力，显著提升了表征学习质量。实验证明，利用领域预训练大模型的输出结果仅需简单后处理（如 MSP 阈值法）即可获得超越已有方法的分布外样本检测性能。

综上所述，本文首次将视觉大模型与自监督学习结合应用于海洋浮游生物图像识别领域，并验证了方案的有效性和应用潜力，为视觉大模型相关技术在海洋浮游生物智能监测领域的应用提供了重要的实践经验，进一步推动了相关研究领域从人工依赖型向数据驱动型的技术发展。

关键词：浮游生物，开集识别，视觉大模型，领域预训练，自监督学习

Research on Recognition of Ocean Plankton Based on Domain-Adaptive Pretrained Large-Scale Visual Models

ABSTRACT

Plankton, as a fundamental component of aquatic ecosystems, plays a crucial role in ecological health assessment, climate change early warning, and biodiversity conservation. Monitoring and analyzing plankton is therefore of great significance. Traditional plankton image recognition methods are constrained by the parameter capacity and feature representation capabilities of convolutional neural networks (CNNs), which struggle to address complex challenges such as long-tail distributions, dataset shifts, and out-of-distribution detection in real-world marine environments. Despite the growing body of research in this area, the full potential of existing deep learning techniques has not yet been fully explored, particularly in terms of applying large visual models in plankton identification. Moreover, there is a lack of successful applications of such models in the field of marine plankton recognition. In this context, this study systematically explores plankton image recognition using large visual models. The research covers end-to-end tasks, including upstream pretraining, downstream closed-set classification, and open-set recognition, providing a novel solution for intelligent marine ecological monitoring.

The study focuses on large visual models, including ViT, Swin Transformer, and ConvNeXtV2, combined with mask-based image modeling techniques. The models were pre-trained on a proprietary large-scale, unlabeled plankton image dataset, and their performance in downstream tasks was evaluated using the DYB-PLANKTONNET annotated dataset. The experiments demonstrate that large visual models, when combined with domain-adaptive pretraining, optimize the initialization of their parameters, significantly enhancing the intra-class compactness and inter-class separability of the feature space. This, in turn, results in substantial improvements in closed-set classification accuracy and open-set recognition robustness. For instance, the ViT-Base model pre-trained with MILAN achieved a classification accuracy of 96.40% in the closed-set task, an improvement of 1.59% over the ResNet50 baseline. The Swin-Large model achieved an AUROC of 92.36% in open-set recognition, with a 95% false positive rate (FPR95) reduced to 43.07%, outperforming existing state-of-the-art methods by over 40%. These results reveal that large visual models, through high-dimensional feature space and hierarchical semantic modeling, along with the incorporation of prior knowledge from domain-adaptive pretraining, effectively mitigate the shortcomings of existing methods in terms of prediction accuracy and the instability of open-set recognition. As a result, they can

maintain stable generalization performance in dynamic marine environments. Furthermore, this study addresses the traditional dependence on labeled training samples by using a self-supervised pretraining approach. This allows the vast amounts of unlabeled data to become a driving force for representation learning, significantly improving the quality of feature learning. The experiments also show that the output of the domain-pretrained large models, with minimal post-processing (such as the MSP threshold method), can achieve superior performance in out-of-distribution sample detection compared to existing methods.

In conclusion, this study represents the first application of large visual models combined with self-supervised learning in the field of marine plankton image recognition. It validates the effectiveness and application potential of this approach, providing important practical insights for the use of large visual models in intelligent monitoring of marine plankton and further advancing the development of data-driven technologies in this research field.

KEY WORDS: Plankton, Open-Set Recognition, Large-Scale Visual Models, Domain-Adaptive Pretraining, Self-Supervised Learning

目 录

第 1 章 绪 论 6

1.1 研究背景 6
1.2 相关研究现状 10
1.3 研究意义及应用价值 13
1.4 论文框架与内容 14

第 2 章 背 景 知 识 16

2.1 迁移学习 16
2.2 自监督学习 16
2.3 掩码图像建模 18

2.3.1 MAE 19
2.3.2 SparK 20
2.3.3 SimMIM 22
2.3.4 MILAN 23

2.4 有监督微调 25

2.4.1 全参微调 25
2.4.2 线性探针 25

2.5 分布外数据检测 25

2.5.1 分布外样本检测与 K+1 分类框架 26
2.5.2 后处理方法 26
2.5.3 训练方法 27

2.6 分类模型的置信度评估与低置信度样本处理 27
2.7 训练框架 28

第 3 章 研 究 设 计 30

3.1 数据集 30
3.2 实验框架 31
3.3 闭集多分类任务 33
3.4 开集识别 34

第 4 章 实 验 结 果 与 分 析 36

4.1 实验指标 36

4.1.1 分类准确率 36
4.1.2 ROC 曲线与 AUROC 37
4.1.3 95%召回率下的假阳性率 37
4.1.4 精确率-召回率曲线下面积 38
4.1.5 风险-覆盖曲线下面积 38

4.2 闭集多分类任务 39

4.2.1 领域预训练与微调方式.....39
4.2.2 多通道特征聚合方法.....43
4.3 开集识别任务.....46
4.3.1 与现有前沿方法的对比分析.....46
4.3.2 领域预训练的作用分析.....47
第 5 章 结 论 与 展 望 52
参 考 文 献 55
致 谢 66

第 1 章 绪论

1.1 研究背景

浮游生物是水生生态系统的基础组成部分，构成了食物网的底层，并在全球生物地球化学循环中起着重要作用[1][2][3][4][5]。作为水生食物链的基础，浮游生物是海洋生态系统变化的敏感指示器。由于浮游生物对温度、营养物质供应、pH 等非生物因素高度敏感，而这些因素调控着它们的生长、代谢和分布，加之它们在水生食物网中的不可或缺性，因此浮游生物群落的监测与分析对于生态系统健康评估、气候变化早期预警以及其对生物多样性和生物地球化学过程的级联影响预测具有重要意义[3]，其丰度和分布的准确信息对于科学管理和保护海洋生态系统至关重要。

浮游生物的监测与分析方法，经历了从传统手动方法到先进自动化系统的巨大变革。显微镜观察和网捕采样等早期方法[6]，虽然提供了基础的分类学信息，但这些方法耗时费力，且易损害脆弱的浮游生物个体。随后，传感器技术的引入极大提升了浮游生物监测能力，使得可以实时、批量地测量浮游生物的生物声学和生物光学特性。这些传感器能够通过检测荧光、光散射和声学信号，间接估算与浮游生物相关的生物地球化学参数[7][8][9][10][11][12]。流式细胞术（Flow Cytometry）是监测精度上的又一重大突破，它通过荧光和散射测量，实现了单细胞的高通量分析[13]。成像流式细胞术（Imaging Flow Cytometry, IFC）进一步推动了该领域的发展，它结合了流体控制、光学表征和高分辨率成像，使得微型浮游生物的分类更加高效和精细[14]。而原位成像系统（In Situ Imaging Systems）的出现彻底改变了浮游生物监测方式，使得可以非破坏性地进行实时观测，并在不同深度和大小范围内大规模收集数据，特别是微型浮游生物（Micro-plankton）至中型浮游生物（Meso-plankton）。这极大提升了浮游生物图像的数量和质量，产生了大量高分辨率的数据集，从而推动了其自动化分析的机器学习方法的进步[15][16][17]。

有效的特征提取，是实现浮游生物准确高效分类的关键。从表示学习的角度而言，浮游生物的图像识别需要构建能够捕捉生物体多尺度形态特征的表征空间。早期的传统机器学习方法依赖于监督学习框架，基于人工设计的特征工程（如浮游生物图像的纹理、几何、形状、颜色、局部，以及部分基于模型的特征等）来构建机器学习分类器[18][19][20][21][22][23]，如支持向量机[24]（Support Vector Machine）和随机森林[25]（Random Forest）。然而，这些主要基于人工特征的实践，由于其特征空间的判别性受限于先验知识的选择范围，因此往往在模型的泛化能力上存在妥协。近年来，随着卷积神经网络（Convolutional Neural Network, CNN）的

快速发展，深度学习方法在特征提取和图像分类方面的能力大大提高。CNN 架构利用其卷积核的共享权重和平移不变性、层次化特征表示、非线性激活和反向传播等多重机制，实现了自动化的高效特征提取，其不仅摆脱了人工特征方法的桎梏，而且在许多浮游生物数据集上取得了较高的分类准确率[26][27][28][29][30]。这些深度神经网络模型极大地推动了基于浮游生物和悬浮颗粒观测的生物海洋学研究进展[10][31][32][33][34][35][36][37][38]，在自动浮游生物识别中表现出色，持续超越传统方法，并在某些情况下超过人类专家，突显了其在自动浮游生物识别中的潜力[39][40][41]。

尽管如此，受限于现有方法所使用的 CNN 模型的参数容量，浮游生物图像的自动识别仍然是一个非常具有挑战性的任务。在现代分类学门纲目科属种的分层分类定种体系中，浮游生物的分类任务所依赖的判别特征往往具有高度特异性，这要求特征提取器具备对细粒度形态特征的强大分辨能力。某些近缘物种的区分标准，也要求模型对局部特征的细微变化保持高度敏感。同时，真实海洋环境下的浮游生物图像识别，还天然存在着极端的类别不平衡问题——其类别分布呈现出典型的长尾特征：海洋浮游生物的类别分布中，存在大量的罕见类别（如图 1 所示），可获取的有效样本数量少且难以为领域专家所辨认，对模型的特征容量和分类准确率形成严峻挑战。甚至，浮游生物的成像过程也呈现出高度复杂的变异性：其成像设备自身参数的差异，采集时间、地点的不同，乃至成像时目标浮游生物自身的大小、形状和状态，都可能对于成像结果产生显著影响（如图 2 所示），进而反映于模型分类结果的明显偏移。上述的种种因素，导致海洋浮游生物的有效识别非常困难，迫切需要表示能力强大的特征提取器。

而参数量较小的传统 CNN 模型（ResNet50 等），难以同时充分地学习到各浮游生物类别的全局形态特征和区分度足够的局部细粒度特征，其有限的特征空间容量，也无法在保证多数类识别精度的同时，维持对尾部类别特征的表征能力。参数规模的约束迫使模型在特征空间的分配上做出妥协，导致训练过程中模型更倾向于过拟合多数类的特征，而无法为稀有类别构建具有判别性的特征表示。由有限的参数容量导致的特征表示能力缺陷，进一步放大了模型在暴露于真实的开放海洋环境中时所面临的分布偏移（Dataset Shift, DSS）与分布外（Out-of-Distribution, OoD）数据检测的困难。

DSS 指的是测试集和训练集间的数据分布或特征-类别映射关系的漂移[42]，这种现象在浮游生物监测中尤为常见。理想情况下，如果训练数据与未来的原位图像数据独立同分布（i.i.d），那么训练出的分类器能够更准确地预测。然而，在实际海水环境中，这一假设几乎不可能成立。例如，中国南海北部大亚湾附近的亚热带水域中的浮游生物类群可能与澳大利亚南部塔斯马尼亚岛附近的温带

水域的浮游生物类群不同——即，不同海域的水文条件变化会显著改变浮游生物的种群组成，而同一区域的昼夜温差与光照周期波动也可能导致生物体表观形态的周期性变异。而现有主流方法所使用的常见 CNN 模型，受限于浅层卷积核的局部感受野与有限的参数容量，难以构建对分布偏移具有鲁棒性的多层次特征表示，其学习到的分类边界往往过度拟合训练集所处的特定时空条件下的数据分布。当此类模型应用于与其训练数据具有时空差异的新数据时，其脆弱的泛化能力将导致性能急剧下降至浮游生物学家完全无法接受的水平[43]。

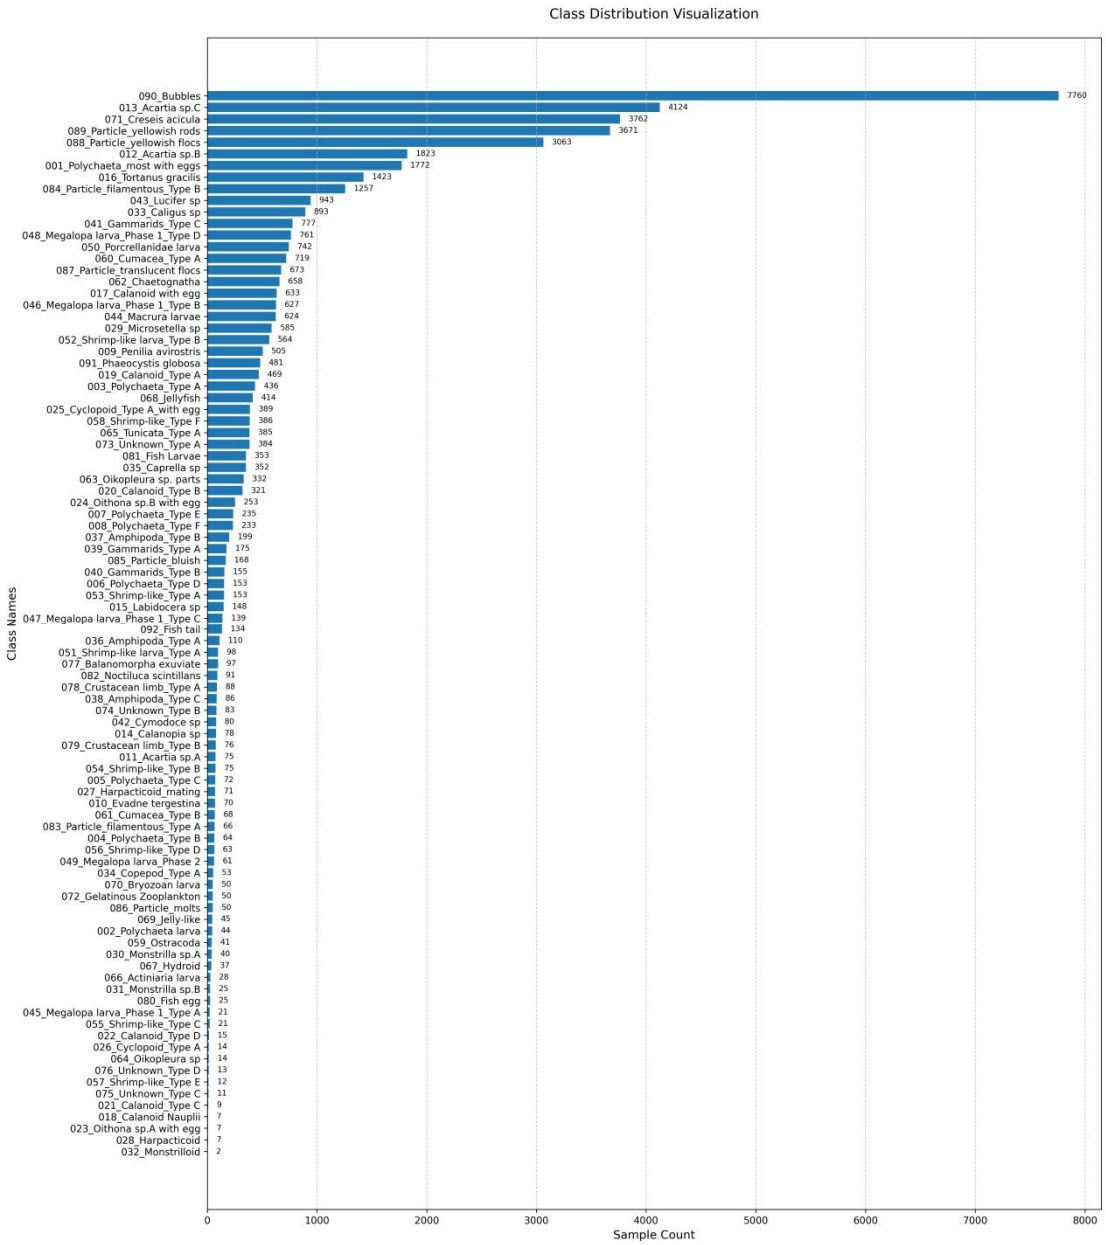

图 1 海洋浮游生物类别分布（以 DYB-PLANKTONNET 数据集为例）

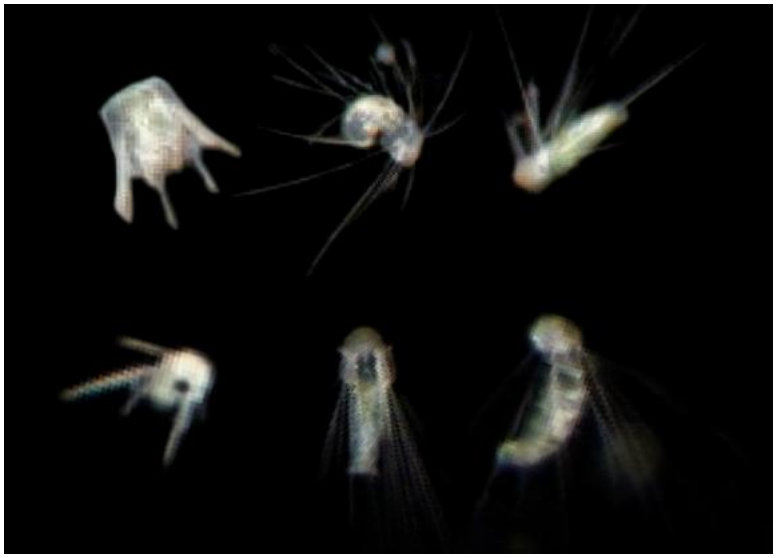

图 2 海洋浮游生物图像的变异多样性（以多毛类幼体类别为例）

OoD 指的是测试集中出现了训练集中不存在的新类别[44]。此类样本不仅包括未在训练集中出现的新物种，还可能包含因成像设备故障或环境干扰产生的异常图像（如气泡遮挡、机械伪影）。OoD 样本的存在，揭示真实海洋环境中的浮游生物图像识别本质上属于开放集问题。而现有实践中所使用的小型 CNN 模型，其有限的参数规模迫使网络在优化过程中过度关注多数类特征，牺牲了对分布外样本的敏感性，从而形成了相对低维和紧凑的特征空间，难以为潜在的新类别预留有效的判别区域，导致模型更容易于将 OoD 样本强行归类至已知类别——这可能对浮游生物监测造成难以察觉的潜在危害[45]：一方面，此类模型容易误将稀有物种判定为常见类，严重影响生物多样性评估；另一方面，对异常图像的高置信度误分类，可能掩盖设备故障等系统性风险。

而无论是长尾分布，DSS 还是 OoD 问题，都揭示出现有 CNN 架构在特征提取和表示能力上与分类任务复杂度之间的失衡，较小的参数规模难以适应复杂的浮游生物识别需求，从而导致模型在真实海洋环境下部署时出现量化不确定性、分类准确率急剧下降等一系列棘手问题[43][45][46]。

相比之下，以 Swin Transformer[47][48]、ViT[49]为代表的视觉大模型，能够凭借其庞大的参数规模优势，突破传统小型模型的性能瓶颈。诸如 Swin Transformer 等大型视觉模型中的局部窗口注意力机制与跨层特征融合等机制，能够充分捕捉浮游生物从宏观形态到微观纹理的跨尺度的语义关联。较大的参数规模能为不同频次类别的特征表示提供充足的空间容量，以构建层次化、多尺度的高维特征空间。这使得视觉大模型不仅能够同时捕获浮游生物图像的全局形态关联与局部细粒度特征，强化对长尾类别微观结构的表征能力，还可以为未知类别预留足够的判别区域，显著降低 OoD 样本被误分类为已知类别的风险。进一步地，现代视

觉大模型所倚靠的掩码图像建模等自监督预训练策略，能够迫使模型从海量无标注数据中学习浮游生物图像的固有结构特征，从而建模更接近真实海洋环境的数据分布等先验知识，缓解因 DSS 所导致的特征-类别映射退化问题，使得视觉大模型可以在动态变化的开放场景中保持稳定的泛化性能。

基于上述背景，本文选择基于目前学术界与工业界主流的视觉大模型以及自监督预训练方法，针对水下浮游生物图像分类所面临的关键问题开展相关研究。

1.2 相关研究现状

当前解决浮游生物图像分类挑战的主流方法主要聚焦于长尾分布、数据集偏移（DSS）和分布外（OoD）检测等问题的局部优化。针对长尾数据分类问题，目前的流行方法包括少数类数据增强[50]、多数类数据下采样[27]和损失重加权[45][51][52][53]等，其总体思想是对背景数据进行下采样，并通过统计方法有意选择难以区分的负样本，以构建一个更为平衡的数据集用于训练。虽然这种方法比简单的随机背景下采样取得了更好的分类准确率，但它需要依赖大规模的有标注数据集，而实际场景中获取足够标注样本的成本极高，且难以应对真实海洋环境的动态特性。对于 DSS 问题，González 等人[43]首先向浮游生物研究界明确了 DSS 的概念，并指出了其对浮游生物量化的影响。他们还建议在处理真实世界数据时使用留一法（Leave-One-Out）策略来进行更合理的模型验证。Li 等人[52]在开发分析浮标携带的浮游生物相机（现称为成像浮游生物探针: Imaging Plankton Probe, IPP）获取的原位图像数据的 ML 模型时，也遇到了 DSS 问题。在明确 DSS 问题的重要性后，González 等人[46]和 Orenstein 等人[45]分别使用 WHOI-Plankton 数据集和 Scripps Plankton Camera 数据集研究了 DSS 问题，针对分类计数法（Classify and Count, CC）、调整计数法（Adjusted Count, AC）、概率 CC/AC 和监督量化方法的效果进行了比较。这两项研究都使用了相对较大的手动标注数据集，并且 Orenstein 等人[45]发现完全监督的量化方法对 DSS 具有最佳的校正效果。Plonus 等人[53]比较了 CapsNet 和 CNN 结合概率过滤方法，来处理使用船拖式视频浮游生物记录仪（Video Plankton Recorder, VPR）收集的浮游生物图像数据中的 DSS 问题。但同样地，这些研究都需要大量的人工工作来进行 DSS 补偿。在 OoD 检测领域，Walker 和 Orenstein 等人[45]应用了 Li 和 Vasconcelos 提出的框架[52]，通过异常暴露（Outlier Expose, OE）技术将分布内（In-Distribution, ID）类和 OoD 类进行区分。Pu 等人[54]通过数据增强技术人工构建了一个辅助数据集作为异常类别，并将其与 ID 浮游生物图像一起用于训练一个带有新 CKA 损失的异常检测（Anomaly Detection, AD）分类器，从而在保持良好 ID 类识别性能的同时实现 OoD 检测。然而，这两项研究没有考虑 DSS 问题，无法在实现 OoD

识别的同时，整合 DSS 问题的相关补偿机制。

上述研究虽在不同维度取得进展，却共同暴露出现有小模型范式下的深度学习分类器在应对真实动态的海洋环境时的根本性缺陷：小型 CNN 模型有限的参数容量所导致的表示能力局限，使得现有方法无法构建统一的表征空间，以同时应对长尾分布、DSS 与 OoD 检测三大核心挑战，最终形成“多问题优化孤岛”。具体而言，受限于小模型的低维特征空间，这些针对个别问题的独立优化方案在优化过程中存在尖锐冲突——长尾分布优化需增强尾部类别的特征判别性，DSS 补偿需提升特征的空间泛化能力，而 OoD 检测则要求特征空间保持对新类别的敏感性，同时优化这三个目标将导致表征学习陷入“跷板困境”：增强某一维度的性能往往以牺牲其他维度为代价。例如，通过过采样尾部类别提升长尾分类准确率时，模型易在多数类上形成过平滑特征，削弱其对 DSS 的鲁棒性；而强制扩大类别间距离以改善 OoD 检测时，又会加剧尾部类别样本在特征空间中的坍缩现象。因此，基于小型模型的主流方法，难以建立兼顾多目标问题优化的统一解决方案。但即使针对单一挑战，小模型有限的特征表示能力，也仍然掣肘着当前主流解决方案的有效性：一旦分类器训练完成，特征空间中类别之间的边界就固定了[55]，而小模型有限的参数规模，导致其倾向于在优化过程中过度拟合多数类特征，所形成的特征空间结构高度耦合，决策边界的冗余宽度也非常有限，无法为尾部类别和未知样本预留足够的判别空间，从而难以适应真实海洋环境中的动态分布变化。尤其当模型部署后遭遇时空分布偏移或新物种出现时，需通过手动校正、人工标注与全模型重训练实现特征边界的重新优化。显然，这会带来巨大的劳动力、时间和经济成本。

这种由模型容量不足引发的表征能力瓶颈，进一步将现有研究范式囿于监督学习的桎梏之中。有限的参数规模难以支撑自监督等数据高效型训练范式所需的表征学习能力，迫使技术路径高度依赖标注数据的强监督信号。而当前主流的监督学习范式对标注数据的过度依赖，已成为制约浮游生物识别技术发展的核心瓶颈。对于浮游生物图像识别的细粒度分类要求，基于 CNN 架构的传统深度学习分类器，通常需要数万张乃至数十万张精确标注的图像进行训练[45]。同时，浮游生物图像标注高度依赖过硬的专业领域知识，其形态多样性、类间相似性及成像条件复杂性（如光照折射、运动模糊、颗粒干扰）导致标注难度远超通用图像任务。即便对于经验丰富的浮游生物学家，区分部分近缘物种时也需耗费相当长的时间，这使得大规模精确标注的人力、时间与经济成本呈指数级增长。标注成本与数据需求间的巨大矛盾，使得现有监督学习方法难以适应大规模海洋监测场景。

当前主流研究方法对监督学习范式的依赖，进而直接导致了当前技术生态

中存在严重的“数据-算法”割裂问题：现有技术体系对海量无标注数据的利用效率严重不足。现代原位成像系统（如 IPP 等）所构成的庞大集群，每日可产出数十万张乃至上百万张高分辨率图像[56]，但受限于监督学习框架的数据利用机制，这些海量的数据常常因缺乏及时高效的标注工作而难以被纳入训练流程。更严峻的是，监督模型的特征表示能力完全受限于标注数据的分布范围，而现有研究多聚焦于有限标注数据集（WHOI-Plankton, Scripps 等）的模型优化，却忽视了无标注数据中隐含的领域特征与分布规律。这种对标注数据的过度依赖不仅导致模型泛化能力受限，更使得算法难以适应真实海洋环境中浮游生物群落的动态变化（如季节性迁移、赤潮爆发等突发生态事件）。尽管自监督学习在医学影像等领域展现出利用无标注数据的潜力[57]，但其在浮游生物识别中的应用仍处于探索阶段，尚未形成系统性的方法论。

与此同时，监督学习范式的局限性和小模型的表示能力缺陷，还加剧了多任务需求间的“孤岛效应”。例如：现实场景中的浮游生物监测需求，可能需要模型能够胜任多种任务特性，涵盖闭集分类、开集识别、目标检测等多项目标：闭集分类用于对已知物种进行快速普查，开集识别需有效甄别未知物种或异常样本，目标检测则精确定位稀有物种的微观结构。但受制于小型 CNN 模型有限的特征表示能力，所能形成的特征空间过于紧凑，无法通过单次训练形成多任务共享的通用表征，从而难以支撑多任务协同优化的复杂需求，因此当前的解决方案多被迫采取任务特异性设计——而传统的有监督学习框架又通常需为每类任务独立设计模型架构与训练流程，这种任务孤岛现象直接导致模型复用性低下，且多任务间的通用特征表示缺乏协同优化。当部署于计算资源受限的海洋观测设备时，会产生显著的存储与能耗负担。更关键的是，分散训练的模型难以共享特征表示，可能因任务目标冲突导致整体系统鲁棒性下降。尽管 Yang 等人[58]尝试引入监督对比学习的方法，提出了基于内容的图像检索（Content Based Image Recognition, CBIR）框架，实现通过动态调整参考库来实现决策边界优化和灵活性提升，展现出了优于传统分类器的环境适应性，但其仍受限于预定义闭集标签，无法动态扩展至开放环境下的多任务协同需求。

上述局限性揭示了当前深度学习技术在浮游生物识别领域的研究和应用范式中所存在的多项核心矛盾：有限模型容量导致的特征表示能力不足与多维复杂任务需求间的结构错配性矛盾、算法对标注数据的强依赖性与领域数据标注的高成本性之间的矛盾、海量无标注数据的可利用性与传统训练范式的低效性之间的矛盾。这些矛盾不仅制约了近年来该领域相关创新研究的进展速度[54][58][59]，其不利影响更是在浮游生物监测从实验室走向现实环境部署的过程中愈发凸显。因此，该研究领域目前亟需探索可以融合能力更强的模型、能够更高效提取更优特

征表示的训练范式的新型技术路径。

1.3 研究意义及应用价值

近年来，以 Transformer 架构为核心的视觉大模型技术在多模态理解、自动驾驶及医学影像分析等领域取得了突破性进展，其通过自监督预训练范式在海量无标注数据中学习通用视觉表征的能力，为复杂场景下的感知任务提供了新的技术范式。然而，在海洋浮游生物图像识别这一领域，视觉大模型的应用仍处于探索初期，现有研究多局限于传统监督学习框架，未能充分释放大模型在开放环境下的泛化潜力。本研究首次系统性探索了视觉大模型与自监督学习在浮游生物图像识别中的全链路适配性，通过构建领域预训练-闭集分类-开集识别的完整技术路径，为后续研究提供了方法论与实践层面的双重参考。

首先，本研究首次相对成功地完成了视觉大模型在浮游生物图像识别领域的有效技术迁移。目前，在海洋浮游生物识别领域，缺乏大型视觉模型的成功应用经验，尤其是针对领域知识大模型的实践研究：即使是已知最前沿的浮游生物识别方法，仍主要采用 CNN 结构的小规模视觉模型作为特征提取模块[54][58]，而通用视觉大模型的直接迁移表现也较为一般，未能体现出其相较于小模型的显著技术优势[59]。同时，当前与视觉大模型相关的主流应用研究，也多聚焦于通用场景（如 ImageNet 分类）或高资源领域（如医学影像、自动驾驶）的性能优化，而对海洋浮游生物这一具有显著领域特异性的边缘场景关注不足。而本文通过对比 MAE[60]、SparK[61]、SimMIM[62]、MILAN[63]四种预训练范式在 ViT、Swin Transformer、ConvNeXtV2[64]等多样化架构上的迁移性能，揭示了领域预训练对浮游生物特征表示的普适增益。例如，MILAN-ViT-B 模型在闭集分类任务中准确率较 ImageNet 预训练基线提升 18.44%，而 SimMIM-Swin-Large 凭借极简掩码策略达到 96.22%的顶尖性能。这些实验数据不仅验证了视觉大模型在浮游生物识别中的可行性，更通过全栈式实验建立了性能评估基准，为后续模型选型与优化提供了关键依据。相较于自动驾驶领域已形成完善的预训练-微调体系，本文首次在海洋生态监测场景中构建了从上游预训练到下游任务适配的技术链条，推动了视觉大模型向边缘科学计算场景的延伸。

其次，本研究突破了该领域传统监督学习范式对标注数据的强依赖性，通过领域自监督预训练实现了数据-算法的协同优化。浮游生物图像标注高度依赖专业领域知识，其形态多样性、成像条件复杂性导致标注成本远超通用视觉任务。本文提出的领域预训练框架以 660,423 张无标注原位图像为基础，通过掩码图像建模（Masked Image Modeling, MIM）与对比学习挖掘数据内在结构，显著提升了模型对长尾分布与分布偏移的鲁棒性。实验表明，基于领域预训练的模型在闭

集分类任务中平均准确率提升 12.8%，而且仅需基于最大 Softmax 概率[65]（Maximum Softmax Probability, MSP）等简单方法即可适应开集识别任务，实现了闭集分类与开集识别的任务统一，且各开集识别指标相较于基线均呈现显著提升：AUROC 最高提升 12.52%（HiViT-B 模型从 74.87%升至 87.39%），FPR95 指标较基线最大降低 19.55%（从 68.49%至 48.94%），E-AURC 指标优化也达到 47.1%。这一成果验证了自监督范式对“数据饥渴”困境的破解能力：通过将海量无标注数据转化为表征学习的驱动力，模型能够更为充分地捕获浮游生物群落的潜在共同特征，从而克服传统方法因标注滞后导致的泛化性不足。

进一步地，本研究提出的基于视觉大模型的技术框架，为动态海洋环境中的浮游生物长期监测提供了新的解决方案参考。真实海域的浮游生物群落受水文条件、季节变化及人类活动的影响，其种群结构与形态特征可能发生显著漂移。传统基于固定数据集的监督模型在此类场景中易因分布偏移、异常域外数据等问题导致性能退化，而本文将视觉大模型与自监督学习的深度融合，利用自监督预训练，可以相对简便地利用海量规模的无标注浮游生物图像，向视觉大模型注入领域先验知识，能够增强模型对浮游生物领域分布特性、长尾类别与开放环境动态变化的鲁棒适应能力。种种结果表明，视觉大模型方案在架构设计、参数容量、训练范式上的协同，在浮游生物图像识别中已展现出超越传统小模型的系统性优势，有望进一步成为海洋浮游生物智能监测的重要技术方案，推动浮游生物研究从人工依赖型向数据驱动型的范式转变。

1.4 论文框架与内容

本文围绕基于视觉大模型的海洋浮游生物图像识别展开研究，全文共分为五章，各章节主要内容如下：

第 1 章阐述浮游生物监测的生态价值及传统方法的局限性，分析现有深度学习技术的瓶颈，提出视觉大模型与自监督学习结合的研究意义，明确论文创新点与应用潜力。

第 2 章介绍所涉及的背景知识，系统梳理迁移学习、自监督学习与掩码图像建模的理论基础，对比分析 MAE、SparK、SimMIM 和 MILAN 等预训练范式的技术原理，为后续实验设计提供理论支撑。

第 3 章展开叙述本研究的方案设计，构建基于大规模无标注浮游生物图像的领域预训练框架，设计闭集分类与开集识别任务实验方案，明确数据集划分、模型架构选择及评估指标。

第 4 章呈现实验结果与相关分析内容，验证本文方案在闭集分类、开集识别场景中的性能优势，以及领域预训练对模型识别鲁棒性的提升，揭示模型架构与

预训练范式的协同优化机制。

第 5 章总结视觉大模型在浮游生物识别中的系统性优势，讨论当前研究的局限性，并提出未来可能进一步完善的研究方向。

第 2 章 背景知识

2.1 迁移学习

数据在训练大型深度神经网络中始终扮演着至关重要的角色。然而，获取一个精心策划且带有标签的数据集不仅需要大量的人力标注工作，还会带来显著的成本，这个问题在海洋浮游生物图像识别等相对边缘的应用领域则尤为明显。迁移学习（Transfer Learning）方法的诞生，为解决此类问题提供了潜在路径——其研究如何利用规模更大、更通用或更专门的源数据集来提升目标数据集/任务的性能[66][67][68][69][70][71][72][73][74][75][76][77]。目前常见的迁移学习方式是：使用源数据上训练得到的模型权重来初始化目标任务的训练[78]，也即所谓的预训练。随后，针对特定的下游任务，将模型进行进一步的优化微调。例如，在大多数图像分类任务中，常见的方法是在 ImageNet 数据集上预训练神经网络[79][80]，然后更换顶端分类器以适配新任务，并在下游任务数据集上进一步训练模型。

然而，下游任务的模型性能，通常和源数据集的规模以及源-目标数据的相似性高度相关：一般而言，模型性能随源数据集的规模和源数据与目标数据的相似度而提升[81][82][83]。因此，迁移学习的一个核心挑战是，当目标数据与源数据不相似时如何提高目标任务的性能。许多研究尝试在目标数据和源数据不相似的情况下提升性能。例如，近期 Peng 等人[84]提出了先在基础数据集上训练，然后在基础数据集的子集上训练专用模型，最后使用目标数据选择最佳的专用模型。类似地，Neumann 等人[85]采用了目标数据对基础数据的重要性进行重加权。

2.2　自监督学习

然而，当源数据与目标数据差异显著时，基于大型通用数据集的传统迁移学习策略，难以直接增益模型在边缘场景的下游任务表现。同时，由于边缘场景的高质量标注数据的稀缺性，单纯依赖基于目标域及其相似域的有监督预训练，难以充分捕获对于目标域任务有益的特性。上述问题同样在海洋浮游生物图像识别场景中十分凸显。

但同时，丰富的无标注数据本身亦可作为迁移学习的潜在桥梁，自监督学习（Self-Supervised Learning, SSL）的出现为其提供了充分的可能性。自监督学习是一种通过自标注数据以学习显著特征表示的无监督预训练方法，它利用数据的固有结构来创建监督环境，而无需人工标注。这种策略可以将迁移学习的源域从"有标注的通用数据集"扩展至"无标注的领域相关数据"，为数据分布不匹配问题提供新的解决路径。值得注意的是，自监督预训练与迁移学习的结合并非完全替代传统范式，而是通过引入更灵活的预训练目标（如实例判别、掩码重建等），

增强模型对目标域特征的捕获能力，同时也继承了传统迁移学习微调机制的高效性。通常，自监督预训练使用无标注的源数据对网络进行预训练，随后将该网络迁移到有监督的目标数据集上进行训练。

近年来，学术界探索了多种自监督学习策略，通过不同的预训练目标，即可使模型能够在无需人工标注的情况下进行训练，同时可以赋能模型学习到丰富的特征表示。在越来越多的深度学习应用中，自监督学习方法的表现超越了传统的监督学习预训练[60][86][87][88]。

由于其潜力巨大，自监督预训练算法在近年来的计算机视觉领域得到了迅速推广，尤其是在标注成本较高的领域（如医学影像和卫星影像）中特别有用[80][89]。在早期的研究中，Doersch， Noroozi 和 Favaro 等人[90][91]受到拼图游戏的启发，他们提出将图像分割为多个区域，并预测每个区域的位置。另一种预训练策略由 Wang 和 Gupta 等人[92]提出，其目标是让视频的起始帧与最终帧之间的距离小于起始帧与另一随机视频帧之间的距离。Pathak 等人[93]则利用视频中物体的运动生成分割图，并通过该人工分割图作为伪标签来执行分割任务。此外，其他典型的预训练任务包括将灰度图像上色[94]或对输入图像进行旋转并预测其旋转角度[95]。其中，实例对比学习（Instance Contrastive Learning）取得了长足的进展——其训练目标是让网络学会区分来源于同一图像的不同增强视图与来源于不同图像的增强视图[78][96][97]，但其对数据增强策略较为敏感，需要进行多次实验以确定最佳设置[98][99]。

然而，自监督预训练需要在大规模数据集上进行长时间训练：例如，SimCLR[88]在 ImageNet 的 120 万张图像上训练到 3200 轮时仍表现出性能提升[80]。由于传统自监督预训练方法的计算复杂度和对超参数的敏感性，在大规模数据集上进行重复实验以获得最佳模型权重的实践，其算力和实践成本难以接受。因此，许多从业者通常不会使用在与其目标数据相似的数据上预训练的模型，而是从模型库（Model Zoos）和研究存储库（Research Repositories）中寻找已有的自监督模型权重，例如采用在大型通用数据集（如 ImageNet）上预训练的公开可用模型，也即通用预训练（Generalist Pretraining）模型。

自监督预训练的实践困难，使得基于领域特定数据集预训练的模型较为稀缺。因此，许多研究人员和工业界从业者通常无法使用在与目标数据相似的数据上预训练的模型，而是倾向于选择在大型通用数据集（如 ImageNet）上训练的公开预训练模型。但是，越来越多的研究表明，在特定领域数据集上进行预训练（即专用预训练（Specialist Pretraining）可以提高模型在下游任务场景下的迁移性能[85][100][101]。充分利用浮游生物成像技术所采集的海量无标注数据，来构建用于自监督预训练的领域数据集，有望突破当前通用预训练模型在边缘领域下游任务上

迁移能力不足的困境。

2.3 掩码图像建模

近年来，掩码语言建模（Masked Language Modeling, MLM）及其自回归变体已然成为自然语言处理（Natural Language Processing, NLP）领域最主要的自监督学习方法。随着双向编码器表示（Bidirectional Encoder Representations from Transformers, BERT）的引入[67]，MLM 取得了突破性的进展。这些方法通过遮蔽部分输入数据，预测输入句子中被遮蔽的不可见词元（Tokens）来学习语言表示，从而在广泛的语言理解和生成任务中实现了卓越的泛化能力。在自然语言处理领域，MLM 的主要优势在于可以利用海量未标注和非结构化的文本数据。MLM 的相关方法在过去的几年间彻底改变了 NLP 研究方向，使得超大规模语言模型的训练成为可能，并利用海量数据推动了语言模型的快速发展。

与此同时，MIM 也在计算机视觉领域逐渐崭露头角。尽管 MIM 与 NLP 领域的 MLM 任务几乎同步发展，但其长期处于非主流研究方向。早期研究如 上下文编码器（Context Encoder）方法通过遮掩图像的矩形区域并预测缺失的像素，开启了这一领域的研究。其中，长期占据着自监督学习主流的对比学习方法，例如对比预测编码（CPC），通过验证任务预测图像补丁，进一步推动了 MIM 的发展。在过去二十年中，研究者还提出了大量其他自监督学习任务来学习视觉表征，包括灰度图像着色、拼图任务、双脑自编码、图像旋转预测和无监督聚类等。尽管这些方法与 MIM 有很大不同，但其中一些方法也采用了类似的思路，即预测输入信号中不可见的部分。例如，颜色通道预测方法通过已知的颜色通道预测其他通道的值。

近年来，随着 ViT 结构的兴起，MIM 任务被重新启用，并通过特定设计提升了其在特征表示学习中的潜力。例如，iGPT 通过对像素进行聚类以改善学习效果，而 ViT 则采用均值颜色预测作为自监督学习任务。BEiT 进一步引入了离散变分自编码器（discrete Variational Auto-Encoder, dVAE）进行图像 token 化，并采用块状掩码策略（Block-wise Masking Strategy），显著提升了模型性能。相比之下，SimMIM 提出了一个极简框架，在实现相似甚至更好效果的同时减少了复杂性。

MIM 任务与基于重建的方法密切相关，特别是自编码器（Auto-Encoder）方法。自编码器通过重建任务恢复原始信号，但其重点在于通过正则化或架构瓶颈约束学习过程，而 MIM 则更关注学习更好的视觉表示。此外，MIM 也可以看作是经典的计算机视觉问题——图像修复的一种形式。尽管图像修复长期以来一直是计算机视觉的核心问题，但其目标更多是提高修复图像的质量，而非直接

关联自监督表征学习。压缩感知（Compressed Sensing）理论也为 MIM 提供了理论支持。该理论认为，大部分数据（包括图像信号）可以被丢弃而不会造成明显的感知损失。稀疏推理研究进一步表明，即使丢弃大量图像特征，识别准确率的下降仍然很小。SimMIM 的研究中进一步发现，仅需极少量的输入图像信息（例如随机选取 10% 的图像补丁），模型仍能学习到良好的视觉表示并完成修复任务。He 和 Xie 等人[60]于 CVPR 2022 提出了一个新的预训练框架，该框架通过对输入进行大比例遮蔽，并利用基于 ViT 的自编码器进行重建，形成了经典的掩码自编码器（Masked Auto-Encoder）方法，为后续视觉预训练大模型的发展产生了深远影响。

从当前流行的掩码图像建模方法中，本研究选取了相对更具代表性以及各评测集指标相对较好的 4 种经典方法（MAE、SparK、SimMIM 和 MILAN 等）用于在私有的大规模无标注浮游生物图像数据集上进行视觉大模型的自监督预训练，并且在以下 4 个小节中详细介绍其具体细节。

2.3.1 MAE

掩码自编码器（Masked Autoencoder, MAE）作为自监督学习领域的重要突破，通过创新的非对称架构设计重新定义了视觉表征学习范式。该方法延续了传统自编码器的基本框架——即通过编码器将输入映射到潜在空间，再由解码器从潜在表征重构原始信号[60]。然而，MAE 在继承经典范式的同时进行了三项关键创新：其一，引入基于 ViT 的高效掩码策略；其二，设计非对称的编码器-解码器架构；其三，采用像素级重建目标实现细粒度表征学习。这些创新使得 MAE 在图像理解任务中展现出超越传统方法的性能优势[60]。

MAE 的核心创新在于其非对称的编码器-解码器架构设计。编码器仅需处理未被掩码的可见图像块，完全省略掩码标记的处理，而轻量级解码器则结合潜在表征与掩码标记完成全局信号重建。这种设计理念突破了传统自编码器对称架构的局限，将计算资源集中于编码器的深度表征学习，同时通过简化解码器结构显著提升训练效率。在预处理阶段，MAE 基于 ViT 框架将输入图像划分为规则的非重叠块（典型尺寸为 16×16 像素）。随后采用均匀分布的随机采样策略，以高达 75%的掩码率对图像块进行稀疏化处理。这种高比例随机掩码策略具有双重优势：其一，通过消除相邻块间的空间连续性，迫使模型建立全局语义关联而非局部外推；其二，均匀分布有效避免了中心区域掩码偏置，确保模型学习均衡的空间感知能力 。值得注意的是，该掩码过程采用无重复采样机制，确保每个掩码决策独立进行，从而最大化信息多样性。

MAE 采用经典的 ViT 编码器架构，但仅作用于可见图像块子集。具体实现包含三个核心步骤：（1）对可见块进行线性投影嵌入，将其映射至潜在空间；

（2）添加可学习的位置编码以保留空间信息；（3）通过堆叠的 Transformer 块进行深度特征提取。与传统 ViT 不同，MAE 编码器完全省略掩码块处理，仅需处理完整图像块的较小比例（典型值为 25%）。这种设计带来了显著的效率提升：当掩码率为 75%时，编码器的计算负载和内存占用大幅降低，使得训练参数量超过十亿级的超大规模模型成为可能。

而 MAE 的解码器采用独立设计的轻量级 Transformer 架构，其典型配置的参数量仅为编码器的 10%。解码器的输入由两部分构成：(1）经编码器处理的可见块表征；（2）共享可学习的掩码标记。每个掩码标记通过添加位置编码保持其空间归属信息，这种设计既保留了待预测块的定位特征，又避免了引入冗余的位置参数。这种非对称设计确保模型将主要计算资源投入编码器的表征学习，同时通过浅层解码器实现高效重建。

重建目标函数的设计体现了 MAE 与自然语言处理中掩码语言模型[67]的深刻联系。具体而言，解码器末层的线性投影层输出通道数等于单块像素数，经形状重组后得到重建图像。损失函数采用掩码块像素空间的均方误差（Mean Square Error, MSE），其数学表达为：

$$L_{MSE} = \frac{1}{|\Omega_m|} \sum_{i \in \Omega_m} \| x_i - \hat{x}_i \|^2 .$$

上式中，Ω_m表示掩码块集合，x_i 和 $\hat{x}_i$ 分别代表原始像素值和重建值。

MAE 的预训练流程经过精心设计以实现最大计算效率，整个过程无需特殊稀疏化操作：首先生成包含全量图像块标记（含位置编码）的完整序列，经随机乱序后按预设掩码率截断尾部子集作为编码器输入。这种实现方式具有两个关键优势：（1）通过张量索引操作即可完成掩码选择，避免复杂的稀疏矩阵运算；（2）逆乱序操作可快速恢复原始空间顺序，为解码器提供规整的输入结构。整个过程通过常规张量操作即可实现，引入的计算开销几乎可以忽略不计。在参数更新策略方面，MAE 采用联合优化模式：编码器参数、解码器参数、投影层权重以及可学习的掩码标记，均参与梯度的反向传播与更新计算。这种端到端的训练方式虽然增加了参数更新维度，但通过非对称架构设计有效控制了计算复杂度。

2.3.2 SparK

在自然语言处理领域，基于 Transformer 架构的预训练-微调范式通过 BERT 与 GPT 的成功验证[24][67][102][103][104]，其强大的表征学习能力长期受到计算机视觉研究者的关注[106]。近年来，随着视觉 Transformer 架构的兴起，研究者成功将 BERT 风格的掩码建模范式迁移至视觉领域[60][105]。这类方法通过将图像掩码比例提升至 60%-75%的激进策略[60]，在 ImageNet 等基准测试中展现出超越传统对

比学习方法[57][107][108]的性能优势，甚至出现掩码建模与对比学习相融合的新型范式[23]。

然而，BERT 的掩码建模范式在 ViT 上有效迁移的成功经验并未在传统的卷积神经网络架构上得到复现。早期的研究[109][110]虽早于 BERT 大规模流行的时代即开始在卷积神经网络上尝试探索视觉掩码建模，但其性能始终无法媲美监督预训练。近期部分研究[111][112]试图突破这一限制，但最终不得不妥协于非卷积架构或非掩码建模策略。

究其根本，自然语言与视觉数据在信息处理层面的本质差异，阻碍了 BERT 范式在卷积网络中的有效应用[60][113]。自然语言处理以离散的词元为基本处理单元，这种显式的语义划分使得掩码操作可直接作用于词元层面[67]。而视觉数据本质上是连续的像素空间，卷积网络必须从原始像素中识别具有多尺度特性的语义实体[114][115]。不同模态数据中语义单元存在的离散性与连续性差异，导致直接迁移 BERT 式掩码策略时面临两个关键挑战：ViT 通过划分非重叠图像块并简单丢弃或替换掩码块[60]，但卷积网络依赖规则网格的滑动窗口操作，难以处理此类不规则输入。若简单将掩码像素置零，则会消除关键的有效信息，导致严重的数据分布偏移。经典视觉系统（如 SIFT 特征金字塔[115]与 FPN 网络[116]） 依赖分层结构处理多尺度目标，而 BERT 式单尺度建模无法充分利用卷积网络固有的层次化特征优势[117]，继而丧失传统方法所拥有的多尺度建模能力。直接将卷积网络架构应用于掩码图像建模时，存在难以调和的适配性矛盾。ViT 通过全局注意力机制能有效处理高比例掩码输入[48][60]，但卷积网络的局部感受野特性与掩码建模的全局推理需求存在本质冲突。相关实证研究表明，当掩码率较高时，传统卷积网络的性能将呈现断崖式下降[112]。

针对上述挑战，Sparse masKed modeling with hierarchy（SparK）框架首次实现了 BERT 式预训练在卷积网络中的有效应用，其核心创新体现在两个层面：1）稀疏卷积与掩码处理的协同设计：受点云处理技术的启发[118]，SparK 将未掩码图像块视为 3D 点云数据，采用稀疏卷积进行特征提取。这种处理方式具有双重优势：其一，通过动态激活稀疏卷积核，精确消除掩码区域的信息干扰；其二，突破传统卷积网络对规则网格输入的依赖，实现不规则掩码模式的高效处理。2）基于多尺度特征的重建机制：为充分利用卷积网络的层次化特性，SparK 设计多尺度掩码嵌入策略：在编码阶段，通过金字塔式下采样获取多级特征图；在解码阶段，在所有空位置填充可学习的掩码嵌入，并通过级联上采样实现多尺度特征融合。这种设计继承自经典特征金字塔网络，但创新性地将掩码建模与多尺度重建相结合。

经实验充分验证，SparK 框架对卷积网络架构具有广泛兼容性：在经典 ResNet 上，其线性探测准确率提升达 12.7%；在现代 ConvNeXt 架构上，下游检测任务性能提升高达 35%。这种普适性源于框架设计中避免引入特定架构的定制

化模块，保持预训练流程的通用性，同时通过可微分稀疏卷积算子实现与现有框架的无缝集成。相较于先前研究，SparK 取得了突破性进展：早期工作[109]受限于卷积网络的局部特性，仅能处理低比例掩码输入（<30%）。SparK 通过稀疏卷积实现 75%高掩码率下的稳定训练，将信息利用率提升 2.5 倍[111]。同时，SparK 实现了性能表现上的飞跃：在 COCO 目标检测基准上，基于 ResNet-50 的 SparK 模型达到 41.2 mAP，超越对比学习方法（MoCo v3）10.3 个百分点，同时较 ViT-Base 模型提升 7.8 个百分点。这种优势在实例分割任务中更为显著，证明其学习到的表征具有更强的空间感知能力。SparK 能够诱导卷积网络学习到更具判别性的边界响应特征，这与传统监督训练产生的平滑特征形成鲜明对比。这种现象印证了掩码建模迫使网络建立全局语义关联的理论假设[60]。

SparK 框架的成功，对视觉研究范式启示：传统卷积网络通过方法论革新仍可释放巨大的潜力，其应用层面的性能瓶颈，可能源于训练范式而非架构本身。该框架为将语言模型的成功经验迁移至其他模态（如点云、光谱数据）提供了可借鉴的范式，特别是稀疏计算与层次化建模的结合策略。

2.3.3 SimMIM

近年来，自监督学习在计算机视觉领域取得了显著进展，其中 MIM 作为一种新兴范式，逐渐受到学界关注。然而，早期 MIM 方法普遍面临两大挑战：其一，复杂的设计流程（如 dVAE 标记化、分块掩码策略）导致预训练效率低下；其二，掩码目标与下游任务的表征学习需求存在潜在割裂。针对这些问题，Xie 等人[62]提出的 SimMIM 框架通过系统性简化设计，重新定义了视觉掩码建模的基准范式。

SimMIM 的核心创新在于摒弃了传统 MIM 方法中复杂的辅助模块，提出了一种极简的三要素架构：（1）基于大尺寸图像块（如 32×32 像素）的高比例随机掩码策略（掩码率 60%-70%）；（2）直接回归原始像素值的轻量级预测头（单线性层）；（3）仅针对掩码区域计算损失的优化目标（L1 损失）。这种设计理念与 BEiT[67]等方法的对比尤为显著：后者依赖 dVAE 进行图像块标记化，并通过多层 Transformer 解码器重建标记，而 SimMIM 证明无需引入额外网络即可实现更优性能：在 ImageNet-1K 分类任务上的微调准确率可直接提升 0.6%以上。

从理论视角看，SimMIM 的成功揭示了视觉信号处理的本质特性。不同于自然语言的离散词元，图像像素具有强空间相关性和连续性[119]。直接回归像素值的策略（而非分类离散标记）更贴合视觉数据的底层特性，这一发现颠覆了早期研究试图模仿 BERT 式分类目标的思路，如 iGPT 的像素聚类[87]。与此同时，SimMIM 通过引入平均预测距离指标，首次建立了掩码参数与模型性能的量化关系，从工程角度为掩码超参数选择提供了可解释的指导原则，也从认知科学视角印证了人类视觉系统依赖中等尺度语义推理的假设[119]。

SimMIM 通过架构创新实现了显著的效率突破：（1）简易的单线性层预测头的 FLOPs，仅为逆 Swin-B 解码器的 43%;（2）预训练速度达到 BEiT 的 1.5 倍。这种效率优势在大规模模型训练中尤为关键：当应用于 3B 参数的 SwinV2-G 时，SimMIM 仅需 JFT-3B 数据量的 1/40 即可完成训练，同时能够在 ImageNet-V2 分类任务中达到 84.0%准确率[48]。该成果为缓解视觉大模型的数据饥渴问题提供了新思路，特别是在医学影像等标注稀缺场景中具有重要应用潜力。SimMIM 的另一个突破在于证明了极简设计对复杂架构的兼容性。实验显示，其在 Swin Transformer 系列模型（Swin-B 至 SwinV2-H）中均取得稳定提升：当模型参数量从 88M 增至 658M 时，ImageNet-1K 微调准确率从 84.0%提升至 87.1%。这种可扩展性源于两方面设计：（1）掩码标记与可见块表征的拼接策略保持空间拓扑结构，适配层次化特征提取；（2）稀疏卷积的引入使框架可扩展至 ResNet 等传统 CNN 架构，在 ResNet-50×4 上实现 81.6%准确率，超越监督基线+0.9%。这打破了“Transformer 专属”的 MIM 范式认知，为卷积网络的生成式预训练开辟了新路径。

SimMIM 的实验发现挑战了多个传统认知：（1）仅预测掩码区域,相比全图重建的微调性能可提升+1.1%（82.8% vs. 81.7%），证明掩码预测更能激发高层语义推理；（2）解码器能力与编码器表征质量并非完全正相关：逆 Swin-B 解码器虽具备更强的图像生成能力（损失 0.3722 vs. 线性层 0.3743），但其下游任务表现反而下降 0.3%，表明过度优化局部细节可能损害全局表征；（3）数据冗余度存在模态差异：视觉数据的高空间冗余允许 60%-70%掩码率，远高于 NLP 的 15%默认值，这一发现为跨模态迁移学习提供了重要参考。

2.3.4 MILAN

在视觉自监督学习领域，掩码图像预训练（Masked Image Pretraining, MIP）近年来已成为突破监督学习数据依赖瓶颈的重要范式。然而，现有的 MIP 方法普遍面临两大挑战：其一，基于像素重建的目标难以捕获高层语义信息；其二，随机掩码策略忽视图像区域的语义重要性，导致预训练效率低下。针对这些问题，MILAN（Masked Image Pretraining on Language Assisted Representation）通过系统性创新，提出了一种融合语言监督的掩码自编码框架[63]。

传统掩码自编码方法（如 MAE）通过回归原始像素值进行重建，但低层视觉信号与高层语义任务存在表征鸿沟。MILAN 创新性地引入 CLIP 模型[120]生成的图像特征作为重建目标，将自然语言监督的语义信息嵌入视觉表征学习，从而利用语言辅助重建目标，实现跨模态语义注入。具体而言，CLIP 通过对比学习在 4 亿图文对上训练的视觉编码器，其输出特征隐含了文本描述引导的语义关联性。实验表明，将 CLIP 特征作为重建目标可使 ViT-Base 模型在 ImageNet-1K 微调准确率提升 0.9%（83.9% vs. MAE 的 83.0%），验证了语言监督对语义表征的

增强作用。

与单纯替换重建目标的方法不同，MILAN 进一步设计了配套的解码架构。当直接使用 MAE 的深度解码器时，模型性能仅提升至 84.1%，而结合 MILAN 架构所提出的提示解码器（Prompting Decoder）后，性能跃升至 85.4%，证明目标与架构的协同设计至关重要。传统解码器（如 MAE）需同时处理掩码块预测与可见块特征优化，导致计算冗余。而提示解码器可通过冻结编码器输出的可见块特征，仅更新掩码块表征，实现更高效的计算（FLOPs 降低 20%）与更优的迁移性能。其关键技术在于：1）在注意力机制中将可见块特征作为静态的键值对，掩码块特征作为动态查询; 2）前馈网络仅作用于掩码块序列。这种设计迫使编码器在可见块处理阶段完成充分的语义提取，而解码器专注于掩码块推理。消融实验显示，提示解码器可使 ViT-Base 的微调准确率提升 1.2%（85.1% vs. 仅替换目标的 83.9%），且训练周期缩短从 MAE 的 1600 epochs 缩短至其 1/4。此外，针对高掩码率（75%）下随机采样可能遗漏关键语义区域的问题，MILAN 提出语义感知掩码采样（Semantic Aware Sampling）方法。该策略利用 CLIP 编码器中类别标记（Class Token）的注意力权重作为区域重要性指标，构建非均匀采样分布。具体而言，通过计算每个图像块对类别标记的注意力贡献，并且以其作为保留概率进行多项式采样。这种机制确保可见区域更可能覆盖语义主体，从而提升编码器特征的质量。实验表明，该策略可使 ViT-Base 在 ImageNet 微调准确率再提升 0.3%（85.4% vs. 随机采样的 85.1%），在 ADE20K 语义分割任务中提升 1.3 mIoU（52.7 vs. 51.4）。

MILAN 在多项下游任务中展现出卓越的泛化能力：1）在 COCO 目标检测任务中，ViT-Base 模型达到 52.6 APbox，较 MAE 提升 2.3 点；2）在 ADE20K 语义分割任务中，ViT-Large 模型取得 57.9 mIoU，创下当时最佳记录；3）在对抗样本（ImageNet-Adversarial）和分布偏移（ImageNet-Rendition/Sketch）测试中，MILAN 的鲁棒性显著优于 MAE 和专用鲁棒模型（如 RobustViT），最高提升达 26.3%。这些结果印证了语言监督对模型泛化性与鲁棒性的增强作用。

理论层面上，MILAN 揭示了重建目标与解码架构的强耦合性：当目标为高层语义特征时，传统解码器的特征更新机制反而可能损害编码器表征质量。通过可视化分析发现，MILAN 编码器的注意力更集中于语义主体，而 MAE 则分散于纹理细节。这解释了为何轻量提示解码器在语义目标下表现更优，而在像素目标下无效。

MILAN 的突破性进展为视觉自监督学习的优化路径提供了重要启示：1）跨模态知识迁移的实践是非常有效的：通过语言模型注入语义先验，可突破纯视觉信号的表征瓶颈；2）在模型层，视觉自监督学习需要重视架构-目标的协同设计：提示解码器的成功实践，证明了目标特性对解码架构的定制化需求；3）在数据层，视觉自监督学习还存在通过改进采样方法来提升预训练效率的潜在优化路径：

MILAN 通过语义感知采样，可将 ImageNet-1K 量级数据的预训练周期从 1600 epoch 缩短至 400 epoch。

2.4 有监督微调

在大规模无标注数据集上完成自监督预训练后，将所得到的视觉大模型权重正式迁移到下游数据集执行分类任务之前，通常还需要对其基于标注数据进行有监督微调后，再评估其在下游闭集多分类任务以及开集识别任务上的性能表现。在本节中，我们主要介绍所使用的 MMPretrain 预训练框架支持的两种主流微调策略：全参微调和线性探针。

2.4.1 全参微调

全参微调（Full Fine-Tuning）指在预训练模型的基础上，针对特定下游任务对整个模型参数进行更新。这种方法通过调整整个网络模型中的分类器和特征提取器的权重，使模型更好地适应新任务的数据分布[121]。全参微调能够充分利用预训练特征，通过端到端优化显著提升模型在特定任务上的性能。例如，ViT-22B（220 亿参数模型）通过全参微调在目标检测、图像分割等任务中展现了与人类视觉感知更一致的特征响应[122]，尤其在形状偏置（Shape Bias）和泛化能力上表现突出。但大模型的全参微调，通常面临计算成本高、内存占用大等经典问题，且通常需要较高的计算资源和数据量以防止过拟合。若目标下游任务数据集较小，容易因过拟合导致泛化性能下降，甚至可能逊于更小规模的模型。

2.4.2 线性探针

相较于全参微调，线性探针（Linear Probe）则是一种轻量化的评估和迁移方法，仅冻结预训练模型的骨干网络，并在其输出的特征表示上训练一个线性分类层。该方法的核心假设是预训练模型的特征提取能力足够强大，仅需简单的线性映射即可适配下游任务。线性探针被广泛用于评测自监督模型的表征能力：例如，DINO 通过自蒸馏训练 ViT 模型，仅用线性分类层即可在 ImageNet 上达到接近全参微调的效果[57]，证明其特征具有高度的任务无关性。但线性分类层的表达能力有限，无法捕捉复杂任务中的非线性关系。尤其是针对细粒度分类或长尾分布数据的场景中，仅依赖单一的线性分类层，可能导致模型的性能瓶颈。

2.5 分布外数据检测

分布外检测在机器学习领域也至关重要，尤其是在浮游生物图像识别等应用中。正如前文所述，已有众多机器学习模型，尤其是深度神经网络，被应用于浮

游生物识别。然而，在真实环境中部署这些模型时，常会遇到与训练数据显著不同的样本，这带来了重大挑战。

这些 OoD 样本可能包含全新或未见过的类别、模式或噪声，这些数据在训练过程中从未被模型接触过。具体来说，在真实的海洋环境当中，存在诸如气泡、光斑、化学杂质与海洋垃圾等大量隶属于非目标类别的无关域外样本，容易对目标浮游生物类别的正常识别造成严重干扰；同时，尚未被当前浮游生物分类学所收录的未知类别生物也可能被捕捉到。而对于现有的主流识别方法而言，其模型的训练过程通常假设所有数据均属于封闭集，即模型仅需在预定义的有限类别内进行分类。但在实际应用中，模型运行在开放集环境下，必须处理超出其训练范围的数据。

同时，一系列研究表明，未能在分类前识别 OoD 样本，往往会导致分类器给出高度自信但完全错误的预测，从而造成无声故障[65][123][124]（Silent Failures）。Giering 等人[32]在这一背景下研究探讨了海洋颗粒图像分类的挑战，指出学习集中缺失的新类别极易发生误分类。因此，针对 OoD 检测问题，设计开发稳健的算法以准确区分输入的 ID 样本和 OoD 样本，对提升模型在真实场景中的可靠性和性能具有重要意义。

2.5.1 分布外样本检测与 K+1 分类框架

OoD 检测的目标是识别非目标类别的未知样本，并对其进行合理处理。处理 OoD 样本的一种常见方法是 K+1 分类框架[125]：预定义 K 个目标类别，其余所有非目标类别样本归入背景类。这一框架通常能够有效应对浮游生物识别中的 OoD 检测问题，它将所有非目标对象（如碎屑、气泡或训练集中缺失的新物种）归入背景类别。多项研究利用了该方法成功提高 OoD 检测场景下的分类准确性和泛化能力：例如，Guo 等人[33]针对中型浮游动物桡足类（Mesozooplanktonic Copepods）的生物识别需求，构建了基于 Zooscan 的八分类体系，通过设立“其他”类别有效处理非目标样本，从而强化了分类边界的清晰度。而 Romagnan 等人[36]聚焦香港水域赤潮预警场景的研究，选取 15 种关键赤潮致藻物种作为核心分类目标，同时引入 10 个环境常见但预警相关性较低的干扰类别，该策略在提升模型泛化能力的同时确保了目标物种的识别特异性。

基于 K+1 分类框架出发，当前针对 OoD 检测的相关研究方法可大致分为两类：后处理（Post-Hoc）方法和训练方法。其中，后处理方法更易于集成，而训练方法更具针对性，适用于提高模型的泛化能力和稳定性。

2.5.2 后处理方法

后处理方法主要包括 OoD 评分（OoD Scoring）和后处理模型增强（Post-Hoc

Model Enhancement）。

OoD 评分方法利用样本特征或模型输出评估样本属于训练分布（ID）的可能性：MSP[65]是最早用于检测 OoD 输入的评分函数；而 ODIN（Out-of-Distribution Detector for Neural Networks）通过温度缩放(Temperature Scaling）和输入扰动（Input Perturbation）提高了 ID 与 OoD 样本的分离能力[126]。能量分数（Energy Score）基于模型输出 logits 计算能量值，旨在降低模型对 OoD 样本的过度自信问题[127]。

后处理模型增强方法通过调整推理过程来改善 OoD 检测性能：ReAct 修改倒数第二层（penultimate layer）的激活值[128]；DICE 通过稀疏化（sparsification）网络权重来提高 OoD 检测能力[129]；ASH 对倒数第二层激活值[130]进行缩放（scaling）和剪枝（pruning）。这些方法通常与 OoD 评分方法结合使用，以获得更好的 OoD 检测效果。

2.5.3 训练方法

训练方法主要通过调整训练过程来增强 OoD 检测能力，其过程通常涉及额外的数据或训练目标的修改：例如，置信度估计（Confidence Estimates）通过为每个输入样本提供置信度估计[131]，可以帮助区分 ID 和 OoD 样本；而固定 Logit 范数（Constant Logit Norm）训练[132]时保持 Logit 范数恒定，以防止模型对 OoD 样本过度自信；此外，Sehwag 等人[133]提出的小样本 OoD 检测（Few-shot OoD detection）方法表明，即使仅使用少量 OoD 样本，也可以显著提升检测性能。

2.6 分类模型的置信度评估与低置信度样本处理

在开放海洋环境下进行浮游生物分类时，除了 OoD 检测，另一个关键步骤是评估模型是否适用于当前测试样本。在机器学习分类任务中，模型在预测时通常会为每个预定义的类别输出：置信度分数[134][135] (Confidence Scores）和概率值[136][137][138][139][140]（Probabilities）。这些值表示模型对预测结果的置信度，通常选择置信度最高的类别作为预测结果。然而，单靠置信度分数或概率值并不总能保证预测的可靠性，尤其是在模型遇到难以分类的测试样本时。例如：如果所有类别的置信度值均匀分布，且最高分数仍较低，说明模型对该样本的预测缺乏信心[141][142][143]。在海洋浮游生物图像分析中，这种情况尤为突出，因为浮游生物形态复杂且变化多样。浮游生物不同物种间常存在视觉特征重叠：许多物种的大小、形状、纹理相似，即便是领域专家也难以区分[125][144][145]。

此外，成像质量的不一致也进一步加剧了分类难度。例如，对焦、光照条件、噪声的变化可能导致图像质量波动。同时，小型浮游生物（如纳米浮游生物，Nanoplankton）的低分辨率图像会对特征提取造成不利影响。胶质浮游生物

（Gelatinous Plankton）由于结构脆弱，在图像中也可能呈现形态扭曲。当输入图像未能清晰匹配训练数据中的模式时，上述的各种因素均有可能导致模型出现低置信度的预测。

为了解决上述问题，在海洋浮游生物图像分类任务中，一个常见的做法是排除低置信度样本。原因在于低置信度样本通常意味着模型预测的不确定性较高，其结果难以信赖。多项研究表明，剔除低置信度样本可以提升整体分类精度[58][115][144][146]。因此，在浮游生物识别系统中，当模型遇到低置信度样本时，通常采取以下处理策略：

1）设定置信度阈值：

2）仅接受高于设定置信度阈值的预测结果，低于该值的样本不作分类。

3）标记低置信度样本并送至专家复核或进一步分析。

4）结合 OoD 检测方法，确保模型不会错误地高置信度预测 OoD 样本。

2.7 训练框架

基于上文所述的各 MIM 建模以及 OoD 检测方法，本文依托计算机视觉任务的经典开源框架 MMPretrain，展开自监督预训练、闭集分类微调和 OoD 检测等相关实验。MMPretrain 是 OpenMMLab 开源生态中的重要组成部分，专注于视觉任务的预训练模型开发与迁移学习。它由 MMClassification 和 MMSelfSup 合并升级而来，旨在提供多样化的预训练主干网络和训练策略，支持图像分类、多模态理解、自监督学习等任务。其核心目标是通过丰富的预训练模型库和模块化设计，降低研究者与开发者的使用门槛，推动计算机视觉模型的快速迭代与应用落地。

MMPretrain 基于 PyTorch 构建，依托 MMEngine 和 MMCV 提供基础支持，架构分为以下核心模块：1）模型定义：包括主干网络（Backbones）、特征融合层（Necks）和任务头（Heads），支持 ResNet、ViT、Swin Transformer 等经典及前沿模型； 2）数据管理：内置多种数据集接口（如 ImageNet、COCO），支持数据增强策略（如随机裁剪、Mixup）和高效数据流水线；3）训练优化：提供灵活的配置文件系统，可自定义优化器、学习率调度、正则化策略等，支持分布式训练与混合精度加速；4）工具链：包含模型复杂度分析（参数量、计算量）、可视化工具（特征热图、CAM 可解释性分析）以及与 MMDeploy 集成的部署功能。

同时，MMPretrain 提供多种预训练策略范式的支持：监督学习（基于大规模标注数据（如 ImageNet）训练基础分类模型）；自监督学习（包括对比学习（SimCLR、MoCo）、掩码重建（MAE、BEiT）等。例如，SimCLR 通过增强图像的特征一致性优化模型，而 MAE 则通过掩码图像块重建任务提升上下文理

解能力）；多模态学习(基于图文对比学习，拉近图文对的特征距离；结合检索、匹配与生成等多种任务，优化多模态表达）。此外，MMPretrain 提供了丰富的模型库，覆盖 ResNet 系列的传统卷积网络、基于 Transformer 的多样化主干网络，以及 CLIP 和 BLIP 等主流的多模态大模型，可支持跨模态检索、图像描述生成等任务。基于 MMPretrain，可以对多种模型实现统一化的高效训练与调优：1）参数化配置：通过配置文件统一管理模型结构、数据增强、优化策略等，便于实验复现与消融分析；2）轻量化评估：支持 Linear Probe 方法冻结主干网络，仅训练线性分类层，快速评估预训练特征质量；3）分布式训练：支持异步计算与混合精度加速等方式优化大型视觉模型的预训练和微调效率。

第 3 章 研究设计

结合视觉大模型以及现代 MIM 自监督预训练等前沿方法，本研究针对海洋浮游生物图像识别中长尾分布、数据集偏移与分布外检测三大核心挑战，从两大主要任务场景——闭集分类与开放环境下的分布外检测出发，基于大规模的私有无标注浮游生物图像数据集以及 DYB-PLANKTONNET 标注数据集[56]，构建了以视觉大模型为基础，覆盖自监督预训练、闭集分类与开集识别的全链路实验框架，尝试突破当前“小模型+纯监督学习”组合的主流方法所存在的性能局限。同时，本研究从领域数据适配性、模型架构兼容性、预训练范式有效性等多个维度展开系统性对比分析，旨在揭示视觉大模型与自监督学习技术在海洋浮游生物识别场景中的有效性和应用潜力。

3.1 数据集

本文所涉及的闭集多分类和开集识别任务等下游任务的相关研究，基于 IEEE Dataport 中所收录的最新版本的 DYB-PLANKTONNET 海洋浮游生物原位图像数据集展开。

图 3 DYB-PLANKTONNET 数据集部分原位成像图像（含浮游生物及 OoD 类别）

本文所使用的领域预训练图像数据集，来自于本研究合作项目组于福建省平潭红山屿、平潭坛南湾，以及广东省深圳大鹏湾等水域所采集的海洋浮游生物原位图像所随机抽样混合而成的，共 660423 张样本所构成的无标注私有数据集。该非公开数据集中的图片成像方式与视觉效果和 DYB-PLANKTONNET 基本保持一致，以确保上游预训练数据集的先验知识能够和下游任务目标良好适配。

在闭集多分类任务中，本文使用 DYB-PLANKTONNET 的全部数据，共 47419 张样本。每个类别按 7:3 的比例进行随机采样，分别构建训练集和测试集。本研究以闭集训练集微调后的闭集测试集分类准确率结果，作为视觉预训练大模型对海洋浮游生物图像特征表示能力的通用性评价指标。

而在开集识别任务中，本文重新将 DYB-PLANKTONNET 每个类别按 8:1:1 的比例进行随机采样和划分，分别构建训练集、验证集和测试集。验证集用于参数调整，以优化模型性能，测试集和 OoD 数据集用于评估模型的识别性能和目标检测能力。由于在开集实验中，所用于对比的方法需要保证训练集、验证集和测试集均至少有一个样本，所以为保证数据集的可用性，仅筛选保留类别数量超过 10 张样本的类别。最终开集识别实验所使用的数据分布情况为：

1) ID 数据：包含 77 个类别（其名称如表 1 所示），共计 30064 张海洋浮游生物图像。

2) OoD 数据：包含 10 个类别，共 17323 张图像，包括：16708 张颗粒 ROI（8 个类别）和 134 张鱼尾部图像，481 张球形棕囊藻图像

3.2 实验框架

本文基于 MMPretrain，针对 ViT、Swin Transformer、ConvNextV2 等现代视觉大模型，结合包括 MAE、SparK、SimMIM、MILAN 在内的多种流行的视觉任务自监督预训练范式，在海洋浮游生物图像数据集 DYB-PLANKTONNET 上展开领域预训练，从而为下游的闭集多分类、开集识别等任务提供具备海洋浮游生物领域先验知识的视觉大模型。

为验证领域预训练对视觉大模型特征表示能力的提升作用，本文在实验中设计了跨范式、跨架构的对比框架。首先，分别采用 MAE、SparK、SimMIM、MILAN 四种预训练范式，在 660423 张无标注海洋浮游生物图像上，对 ViT、Swin Transformer、ConvNeXtV2 等主流视觉大模型架构进行 200 轮次的自监督 MIM 预训练。对照组则直接使用各预训练范式仅在 ImageNet-1k 进行预训练所获得的模型权重，从而对比量化海洋浮游生物领域数据与通用数据的先验知识间存在的表征差异，以验证领域预训练有效性的相关假设：其一，掩码图像建模能通过像素级重建任务，强化视觉大模型对浮游生物细粒度特征的捕捉和区分能力；其二，

领域数据的分布特性，以及目标域外样本特征相关的先验知识，可通过自监督学习注入模型参数，从而缓解下游任务的分布偏移以及 OoD 样本误识问题。

为保证对比的公平性，研究涉及的所有实验采用 MMPretrain 框架统一实现，训练过程中批次大小均设置为 128，输入图像分辨率固定缩放为 224×224 大小，优化器均采用 AdamW 并配合余弦退火学习率调度，数据增强仅包含随机旋转、翻转与归一化，避免过度修饰破坏原始图像的固有特征分布。测试时均使用单一的居中裁剪处理测试数据，并且不使用额外的测试时数据增强。上述实验设置以期通过相对标准化的流程尽可能排除超参数的干扰，使评估结果所反映的性能差异可明确归因于各模型架构以及预训练范式的内在特性。

表 1　分布类样本类别名称

多毛类	多毛类幼体；多毛类 A；多毛类 B；多毛类 C；多毛类 D；多毛类 E；多毛类 F
水蚤类	纺锤水蚤 A；纺锤水蚤 B；纺锤水蚤 C；长足水蚤；唇角水蚤；瘦歪水蚤；哲水蚤带卵；哲水蚤幼体；哲水蚤 A；哲水蚤 B；哲水蚤 C；哲水蚤 D；长腹剑水蚤 A；长腹剑水蚤 B；剑水蚤-带卵；剑水蚤；猛水蚤-疑似交配行为；猛水蚤；小毛猛水蚤；怪水蚤 A；怪水蚤 B；怪水蚤
甲壳类	鱼虱-管口目；桡足类；麦秆虫；端足类 A；端足类 B；端足类 C；钩虾 A；钩虾 B；钩虾 C；尾突水虱；莹虾；长尾类幼体；大眼幼体_Phase1-A；大眼幼体_Phase1-B；大眼幼体_Phase1-C；大眼幼体_Phase1-D；大眼幼体_Phase2；磁蟹幼体；虾的幼体 A；虾的幼体 B；虾类 A；虾类 B；虾类 C；虾类 D；虾类 E；虾类 F；涟虫 A；涟虫 B
桡足类及其他小型甲壳类	鸟喙尖头溞；肥胖三角溞；介形类
无脊椎动物	住囊虫部分；住囊虫；被囊类
水母类及其他胶质动物	海葵幼体；水螅体；小水母；多种水母；胶质浮游动物
其他	毛颚类-箭虫；尖笔帽螺；幼鱼；夜光藻；鱼卵；草苔虫幼体；甲壳动物残肢 A；甲壳动物残肢 B；藤壶蜕皮

3.3 闭集多分类任务

通常而言，自监督预训练模型的特征质量一般基于以下标准进行评估：

1）可分离性（Separability）：测试线性模型是否能够利用学习到的特征区分数据集中的类别。良好的表征应该是线性可分离的[147][148]。

2）可迁移性（Transferability）：测试模型在新数据集和任务上进行微调时的性能。更好的表征应该能够泛化到更多任务[97]。

3）半监督评估（Semi-supervised）：测试模型在有限标注情况下的性能。更好的表征在标签数量减少时性能下降较少[149][150]。

由于本文主要关注领域预训练的视觉大模型在海洋浮游生物图像识别这一相对边缘的专业性问题上的表现，且 DYB-PLANKTONNET 标注数据集自身的容量和标注数据规模已经相对有限，因此，本文主要从可分离性的角度评估模型的特征表示能力，即经过领域预训练的视觉大模型，能否从所给出的浮游生物图像中提取出区分度足够高的特征，以至于仅需要简单的线性分类方法，便能够取得相当高的分类精度。

由此，在大规模无标注浮游生物图像数据集上完成自监督预训练后，我们将最终模型迁移到下游数据集 DYB-PLANKTONNET 的多分类任务中进行监督微调。为探讨分析视觉大模型和 ResNet50 等轻量级网络在特征表示能力上存在的差异，本文将现有主流方法所最常用的 ResNet50 架构作为传统的小型 CNN 模型代表，并将其在该数据集上的有监督微调结果设置为实验的基线对照组，用于揭示模型容量与任务复杂度间的内在矛盾。

针对前述领域预训练实验中所涉及的视觉大模型，本文从微调策略、预训练范式、模型架构等多个层面展开比较分析。在闭集多分类任务当中，本文采取 mmpretrain 框架所支持的两种主流微调策略：全参微调和线性探针，来评估其在下游闭集多分类任务上的性能表现：全参微调允许所有层参数更新，旨在最大化模型对下游任务的适配性；线性探针冻结骨干网络仅训练分类头，用于评估预训练特征的内在可分性。全参微调与线性探针的差异，能够反映视觉大模型经过领域预训练后所提取特征的泛化性：若线性分类器性能接近全参微调，则表明模型已学习到高度线性可分的表征空间。

进一步地，各自监督预训练范式的横向对比，可揭示不同 MIM 实现方式对视觉大模型所提取的特征的判别性的影响：例如，SparK 通过稀疏卷积保留局部细节，可能更适应浮游生物的微观结构分类，而 MILAN 引入 CLIP 语义监督，则可能对形态相似物种的区分能力起到一定的强化作用。而 ImageNet-1k 通用预训练与领域预训练的对比，旨在验证基于大规模无标注数据集的自监督预训练能否逾越通用视觉任务与海洋浮游生物图像识别的巨大域间差异。而在模型层面，纯 Transformer 编码器架构（ViT）与层次化架构（Swin、ConvNeXtV2、HiViT[151]）

的对比，可进一步反映局部归纳偏置与全局注意力机制在浮游生物多尺度识别中的差异及其形成机制，为相关任务的模型设计与选择方案提供重要参考。

在多分类任务中，我们使用 Top-1 准确率评估模型性能，同时使用 t-分布随机邻域嵌入可视化和类别激活图等工具对不同模型的特征表示能力进行可视化分析。闭集微调实验按照 MMPretrain 针对各模型架构提供的参考配置，设置 200-300 轮次训练周期。由于 MMPretrain 框架对于 ViT 模型的特征聚合支持平均池化、最大池化、CLS Token 等三种方法的自定义选择，本文还在闭集实验中探究了不同空间特征融合机制对其下游任务分类性能的影响。

3.4 开集识别

在真实海洋监测场景中，浮游生物图像识别系统不仅需要处理已知类别的分类任务，还需具备对分布外样本的甄别能力以及模型不确定性的量化评估机制。因此，本研究针对开放环境下的动态特性，构建了覆盖 OoD 检测与低置信度样本处理的实验框架，旨在系统验证视觉大模型与领域预训练在开集识别场景中的综合性能优势。

实验框架的核心目标在于揭示视觉大模型在开放环境下的泛化能力突破，重点考察两个维度：视觉大模型与传统方法在开集识别任务上的性能差异，以及领域预训练对视觉大模型特征空间分布特性的改造效应。前者通过横向对比现有的 SOTA（State of The Art）浮游生物图像开集识别算法展开，后者则从纵向比较基于通用预训练或领域预训练的同架构模型在下游开集识别任务上的性能差异出发，分析领域预训练是否能够增强视觉大模型对开集识别任务的适应能力。

在横向对比实验中，本文选取了三种目前学界最前沿的浮游生物开集识别方法作为基准参照，以对比本研究的最佳实践结果。其中，Pu 等人[54]从引入辅助信息的角度出发，通过数据增强构造辅助数据集，并且在模型预训练过程中利用辅助数据集注入分布外数据的先验知识，实现对正常类别的准确分类和对异常类别的有效检测，并在后训练阶段利用检测器将预训练模型所提取的图像特征转换为得分，来进行异常判别；而 Ciranni 等人直接使用 ImageNet-1k 预训练的 ViT 模型提取图像的深度特征[59]，再通过主成分分析（PCA）对特征进行降维后，针对训练集中每个可用类别都训练一个单独的异常检测器（如单类支持向量机，One-Class SVM），根据所有检测器返回的全局置信度结果判定 OoD 样本；Yang 等人则尝试结合监督对比学习（Supervised Contrastive Learning, SCL）方法和 CBIR 技术的优势，构建了一种基于对比学习的浮游生物图像检索框架[58]（IsPlanktonIR），其核心思想是通过对比学习训练特征提取器，以增强图像特征的表示能力，同时利用图像检索的灵活性，基于大量的标注图像构建了一个参考特征库，通过比较输入图像与参考特征库（gallery）之间的相似度来确定查询

图像是否为已知 ID 类别，以灵活适应复杂海洋环境中的数据变化。这些方法均基于传统 CNN 架构或小型 ViT 模型，并主要采用监督学习范式构建 ID 和 OoD 分类器。相较之下，本研究方案依托视觉大模型架构，结合自监督预训练构建统一的表征空间，在下游任务只针对 ID 样本分类进行全参微调，而开集识别场景下的 OoD 检测则仅通过 MSP 阈值法的简单后处理策略来实现。

在纵向实验设计中，本文则着重探讨领域预训练和模型架构在开集识别场景下对模型的特征表示能力的影响及其机制。在开集任务中，我们仍然使用与闭集多分类实验中相同的各领域预训练模型权重，而对照组采用相同架构但仅基于 ImageNet-1K 通用数据进行过预训练的模型权重，确保实验变量仅存在于预训练数据的领域相关性，以及模型自身的架构设计。所有模型均在重新划分的 DYB-PLANKTONNET 数据集上通过全参微调完成下游任务适配，并统一采用 MSP 方法进行 OoD 样本判别，以消除后处理策略差异的影响。

第 4 章 实验结果与分析

4.1 实验指标

我们采用以下标准来评估各 MIM 预训练范式、视觉大模型在下游的闭集分类识别和开集识别任务中的性能，其中开集识别任务涉及两个方面：

1）分类模型应当能够有效处理 ID 样本和 OoD 样本，并能高效地识别 OoD 样本；

2）识别并合理处理超出模型判别能力的困难样本。

在 ID 样本的分类任务中，准确率（Accuracy,ACC）是衡量模型分类性能的有效指标。对于分布外检测（OoD Detection）任务，我们选取受试者工作特征曲线下面积（AUROC）和 95%召回率下的假阳性率（FPR95）作为评估指标，其中 ID 样本被视为正类，OoD 样本被视为负类。此外，精确率-召回率曲线下面积（AUPR）也是衡量模型检测 OoD 样本能力的重要指标，在此情况下，OoD 样本被视为正类。

最后，我们选择风险覆盖曲线下面积（AURC）和 E-AURC 作为不确定性估计的评估指标，以衡量模型是否适用于给定的测试样本。

4.1.1 分类准确率

准确率是机器学习中用于评估分类模型性能的基本指标之一，衡量模型预测正确的样本数（包括正类和负类）与总样本数之比，适用于二分类和多分类任务。

对于二分类问题，基于混淆矩阵的四个基本元素：

1）真阳性（TP）：实际为正类，预测为正类。

2）真阴性（TN）：实际为负类，预测为负类。

3）假阳性（FP）：实际为负类，预测为正类。

4）假阴性（FN）：实际为正类，预测为负类。

即可导出准确率的计算公式为：

$$\text{Accuracy} = \frac{\text{TP} + \text{TN}}{\text{TP} + \text{TN} + \text{FP} + \text{FN}}.$$

准确率的计算可以扩展至多分类问题场景：对于 N 个类别，准确率即等于所有类别中正确预测的样本数之和除以总样本数。

当数据集的类别分布相对均衡时，准确率是一个直观有效的评估指标。但在类别极端不平衡的数据中，准确率可能产生误导。例如，在异常检测中，极端离群数据仅占整体比例的 1%时，分类模型仅需将所有样本预测为正类即可达到 99%

的高准确率，但对目标任务的解决毫无帮助。

综合准确率这一指标计算简单，易于理解，适合快速评估模型整体表现的特点，在本文中，我们将准确率仅作为评估 ID 数据分类性能的主要指标，反映预训练模型在总体上对于各已知类别的特征表示能力。较高的准确率表明当前预训练模型对训练集已知类别的特征表示能力较强，能够提取具有良好区分度的类别特征，从而经过微调后能够在训练集中出现的已知类别上表现出较强的识别能力，

4.1.2 ROC 曲线与 AUROC

ROC 曲线（Receiver Operating Characteristic Curve）描绘了真正例率（True Positive Rate, TPR）与假正例率（False Positive Rate, FPR）之间的关系。其横轴为假阳性率（False Positive Rate, FPR），即实际为负类的样本中被错误预测为正类的比例：

$$\mathrm{FPR} = \frac{\mathrm{FP}}{\mathrm{FP} + \mathrm{TN}}.$$

纵轴为真阳性率（True Positive Rate, TPR，也即召回率），表示实际为正类的样本中被正确预测为正类的比例：

$$\mathrm{TPR} = \frac{\mathrm{TP}}{\mathrm{TP} + \mathrm{FN}}.$$

通过调整分类阈值（如逻辑回归中的概率截断点），计算不同阈值下的（FPR, TPR）点，连成曲线即可绘制 ROC 曲线。

AUROC（Area Under the Receiver Operating Characteristic Curve）表示了 ROC 曲线下的面积，是评估分类模型性能的核心指标之一，尤其适用于类别不平衡或需权衡分类错误代价的场景。它通过量化模型在所有分类阈值下的综合表现，全面反映模型区分正负类的能力。针对本文中所涉及的开集识别场景，AUROC 可以将所有可能的分类阈值纳入考量，综合反映模型对 ID 样本与 OoD 样本的区分能力。较高的 AUROC 值即表明模型在检测 OoD 样本方面具有较强的能力。

4.1.3 95%召回率下的假阳性率

在二分类问题中，95%召回率下的假阳性率（FPR95, False Positive Rate at 95% TPR）表示当 TPR 达到 95%时对应的 FPR 值，即在模型能正确识别 95%的正例时，负例被错误分类的比例。

对于本文中所涉及的开集识别场景，我们使用 FPR95 表示当 TPR 限定在 95%时，模型将 OoD 样本误分类为已知类别样本的概率。由此，较高的 FPR95 值说

明：在指定 95%召回率水平时，模型容易将大量的 OoD 样本错误地预测为 ID 样本。这通常意味着模型在高召回率下区分 OoD 样本的能力较差，从而导致较高的假阳性率。

4.1.4 精确率-召回率曲线下面积

在简单二分类问题场景中，精确率（Precision）表示预测为正类的样本中实际为正的比例：

$$\text{Precision} = \frac{\text{TP}}{\text{TP} + \text{FP}}.$$

召回率（Recall）表示实际为正的样本中被正确预测的比例：

$$\text{Recall} = \frac{\text{TP}}{\text{TP} + \text{FN}}.$$

AUPR（Area Under the Precision-Recall Curve）是精确率-召回率曲线（PR 曲线）下的面积，用于衡量分类模型在类别不平衡问题中的性能。PR 曲线通过在不同分类阈值下绘制精确率（Precision）和召回率（Recall）的关系，直观反映模型的权衡能力。相较于更关注全局性能，对负类数量敏感的 ROC 曲线（TPR vs. FPR），PR 曲线关注正类性能（Precision vs. Recall），适合类别不平衡场景。AUPR 综合了 Precision 和 Recall 在不同阈值下的表现，是类别不平衡问题的核心评估指标。

在本文所涉及的浮游生物开集识别场景中，我们在计算 AUPR 时进行正负样本的标签翻转，即将 OoD 样本视为正类，从而能够使得 AUPR 更关注对 OoD 样本的预测性能。此时，较高的 AUPR 表明模型在 OoD 样本检测方面具有良好的性能。

4.1.5 风险-覆盖曲线下面积

风险-覆盖（Risk-Coverage, RC）曲线描绘了选择性风险（Selective Risk） 随着覆盖率（Coverage）变化的情况，可用于评估置信度评分函数（Confidence Scoring Functions）的质量。其中，覆盖率（Coverage）指置信度估计超过某一阈值的样本比例，而风险（Risk）则表示这些样本的分类错误率。AURC（Area Under the Risk-Coverage Curve,风险-覆盖曲线下面积）使我们能够对未知测试样本的评分函数质量进行有意义的评估。

直观上，一个优质的评分函数应当能够使选择性分类器（Selective Classifier）拒绝那些分类器容易误分类的样本，从而使得 RC 曲线在覆盖率降低时快速下降，并使 AURC 值较小。较低的 AURC 值说明正确和错误的预测能够被良好地区分

开，表明模型的置信度估计更具可靠性。

进一步地，对 AURC 进行归一化处理，可导出超额 AURC（E-AURC, Excess AURC），其计算方式是从 AURC 值中减去理想情况下的最优评分函数 AURC 值[152]。E-AURC 是一个无单位（unitless）指标，其取值范围为[0,1]，从而可以用于不同任务间的公平对比。E-AURC 值越小，表示模型的置信度评分函数越接近最优，即模型在不确定性估计和选择性分类方面的性能越好。

基于上述各项评估指标，我们能够全面且综合地评估各自监督预训练范式及其相应的视觉大模型，在闭集和开集识别场景的下游任务全链路的性能表现。

4.2 闭集多分类任务

4.2.1 领域预训练与微调方式

本节的实验主要针对 2.3 节中所涉及的 4 种预训练范式，基于 mmpretrain 所支持的相应骨干网络，先在 660423 张海洋浮游生物原位图像所构成的无标注数据集完成 200 轮次的掩码图像建模自监督预训练，再将获得的预训练模型权重，在所划分的 DYB-PLANKTONNET 训练集上按照 mmpretrain 所给出的下游任务参考参数配置，通过全参微调或线性探针等方式完成后训练，最终在所划分的 DYB-PLANKTONNET 测试集完成评测。

对于小模型方法的对照组和基线标准，本文采用了在 ImageNet-1k（Deng 等, 2009）上进行过有监督微调（Supervised Fine-Tuning, SFT）的 ResNet50 作为传统浮游生物分类算法中所使用的小型 CNN 模型代表。此外，本文还选取了 4 种预训练范式下，仅在 Imagenet-1K 进行预训练的对应模型权重，作为大模型的通用预训练对照组，该对照组模型直接在所划分的 DYB-PLANKTONNET 训练集上使用与领域预训练模型完全相同的参数配置，进行全参微调或线性探针等后训练，并比较其在测试集上的准确率差异。

若视觉大模型的评估结果，相较于 ResNet50 有较为明显的提升，则可以反映视觉大模型的特征表示能力相较于传统识别方法中所使用的简单 CNN 模型的优势。若经过大规模浮游生物无标注数据集进行过领域预训练的模型性能指标，相比于仅 Imagenet-1K 通用预训练的模型指标有明显增幅，则可以反映出领域预训练方法的有效性：其能够缓解通用领域知识和浮游生物图像特征的巨大域间差异，提升视觉大模型对于海洋浮游生物原位图像的特征提取与表示能力，从而针对下游的闭集分类任务产生显著增益。实验定量结果如表 2 所示，各模型的 t-分布随机邻域嵌入可视化分析与类别激活图如图 4、图 5 所示。

表 2　视觉预训练和微调方式对闭集分类任务的影响（%）

预训练范式	网络架构	领域预训练	后训练方式	后训练轮次	准确率 Top-1
SFT	ResNet50	否	全参微调	200	94.8104
SFT	ResNet50	否	线性探针	200	94.2174
SparK	ConvNeXtV2-tiny	否	全参微调	300	94.3576
SparK	ConvNeXtV2-tiny	否	线性探针	300	93.8987
SparK	ConvNeXtV2-tiny	是	全参微调	300	96.0678
SparK	ConvNeXtV2-tiny	是	线性探针	300	96.0678
SimMiM	Swin-Large	是	全参微调	200	96.2221
SimMiM	Swin-Base	是	全参微调	100	96.1446
SimMiM	Swin-Large	否	全参微调	200	91.3296
SimMiM	Swin-Base	否	全参微调	100	88.4489
SimMiM	Swin-Large	是	线性探针	200	95.8477
SimMiM	Swin-Base	是	线性探针	100	95.5988
SimMiM	Swin-Large	否	线性探针	200	89.4284
SimMiM	Swin-Base	否	线性探针	100	86.7396
MAE	ViT-Large	是	全参微调	200	91.2666
MAE	ViT-Large	是	线性探针	200	89.2549
MAE	HiViT-Large	是	全参微调	200	93.9511
MILAN	ViT-Base	是	全参微调	200	96.4043
MILAN	ViT-Base	是	线性探针	200	96.3692
MILAN	ViT-Base	否	全参微调	200	78.4538
MILAN	ViT-Base	否	线性探针	200	77.6267

从表的结果可以分析得知，领域预训练的视觉大模型整体性能指标达到 96% 以上，明显超过 ImageNet-1k 监督预训练的传统 ResNet50 模型的 94.81% 基线指标，充分展现出视觉大模型在参数规模、特征提取和表示能力上的系统性优势。同时，领域预训练的相应模型，在 DYB-PLANKTONNET 的下游闭集分类任务中的表现，均显著优于仅在 Imagenet-1K 进行过预训练的对照组的微调结果（例

如，ViT-Base 在未经过 MILAN 范式进行领域预训练时，下游任务准确率低至 77.63%，而通过领域预训练后提升可达 18.77%），充分反映了基于无标注领域数据集的领域预训练，对视觉大模型的性能增益具有普遍性。但值得注意的是，未经领域预训练的视觉大模型，其性能指标也普遍逊于传统 ResNet50 模型，体现了视觉大模型在上下游任务差异巨大的迁移实践中存在的微调困难，更反映出领域预训练对于视觉大模型向边缘领域成功迁移学习起到了至关重要的作用——其无需经过复杂繁琐的超参数选择和调优策略，即可将视觉大模型的性能十分简便地提升至先进水平。这一结果对期望在视觉任务中借助大模型工具的各边缘学科领域的研究者能够起到重要的警示和启发作用：对于上下游任务域差异巨大的场景，将大模型拿来即用，直接微调的传统实践方法并不可取——其难以充分释放大模型的真实潜力，甚至可能无法匹及小模型的简单方案。

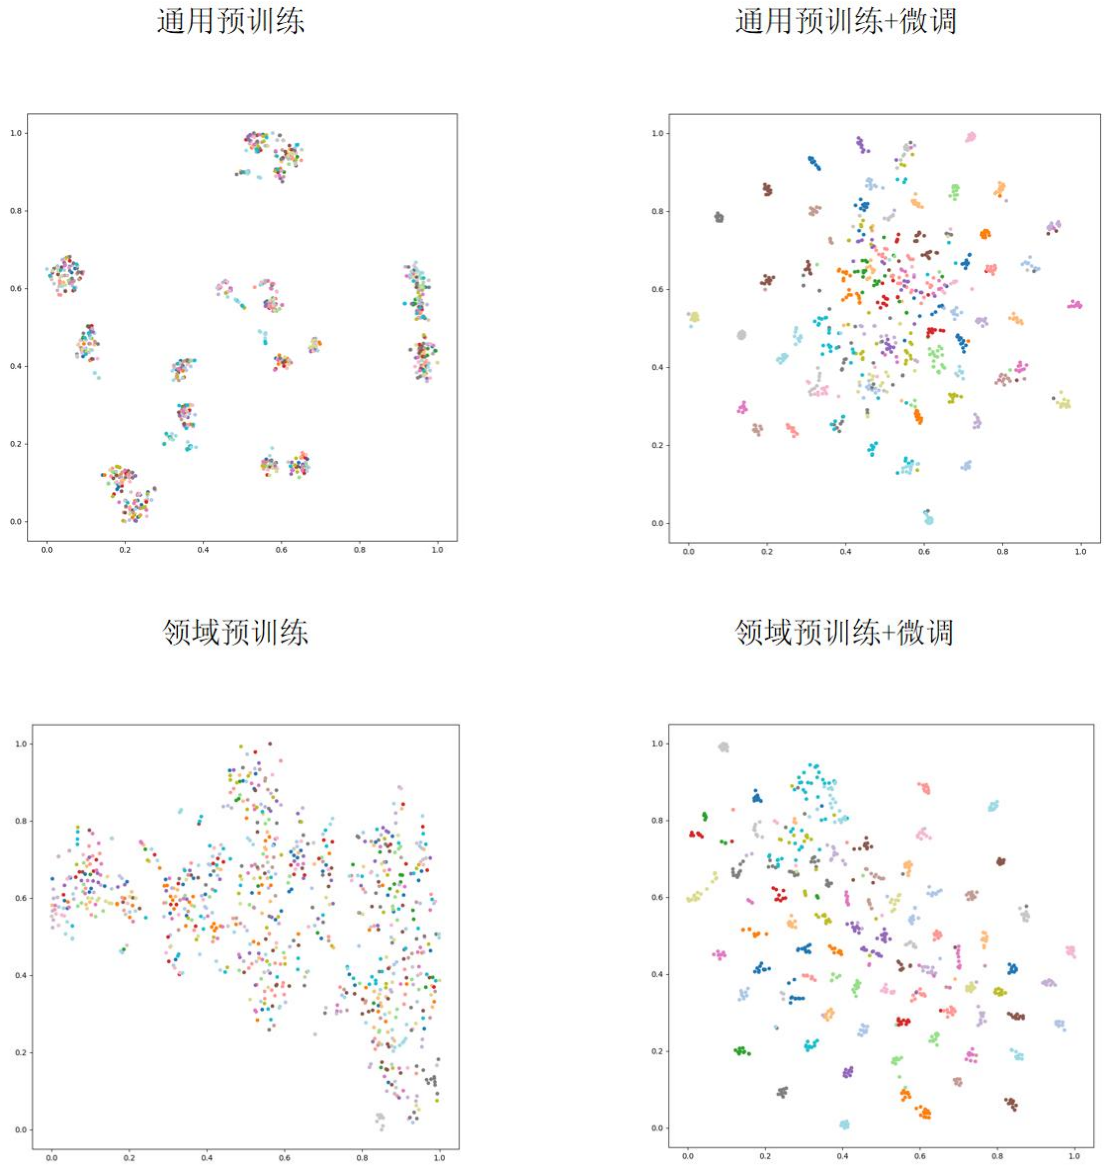

图 4 各模型特征嵌入的 t-分布随机邻域嵌入（t-SNE）可视化（以 Swin-Large 为例）

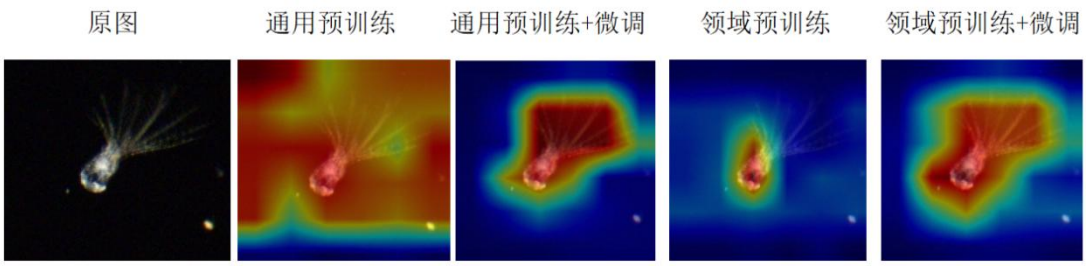

图 5 各模型的类别激活图（以 Swin-Large 为例）

t-SNE 可视化与类别激活图等定性分析的结果，也从侧面佐证了领域预训练的有效性：从图 4 所示的 t-SNE 可视化结果可知，仅基于 ImageNet-1k 通用预训练的视觉大模型，由于缺乏浮游生物图像的领域先验知识，其编码得到的不同浮游生物类别的特征嵌入高度紧密地耦合于特定区域，使之在微调过程中更加难以分离，而领域预训练使得浮游生物图像的特征嵌入相对均匀地分散在特征空间中，从而更容易在微调过程中区分开；同时，图 5 的类别激活图也展示了，缺乏浮游生物图像领域先验知识的通用视觉大模型，倾向于将浮游生物图像中的无效区域高度激活，体现出通用大模型对于常见视觉图像分布的过拟合，即使通过微调，模型也倾向于给出更加自信的激活权重预测。而领域预训练仅通过自监督的 MIM 预训练，即可将模型的注意力权重集中至浮游生物图像的关键特征区域，并且使得微调过后的模型，在对测试图像给出预测时，其激活权重相对更加鲁棒。

此外，表 2 中的定量实验数据还进一步揭示了不同预训练范式、网络架构及训练策略对下游任务性能的显著影响。在预训练范式对比中，SparK 与 SimMiM 展现出更高的准确率，例如，ConvNeXtV2-tiny 在经过 SparK 领域预训练后可达到 96.07% 的 Top-1 准确率，而 MILAN 领域预训练后的 ViT-Base 与 SimMiM 领域预训练后的 Swin-Large 更是以 96.40% 和 96.22% 的准确率领先。相比之下，MAE 的表现相对较弱，尽管其使用的 ViT-L 以及 HiViT-L 参数规模最大，但全参微调准确率仅为 91.27% 和 93.95%，说明领域继续预训练的有效性与模型架构和训练策略均密切相关：SimMiM 能够通过领域预训练将 Swin-Large 架构的下游任务准确率从 88.45% 提升至 96.22%，验证了 Swin 架构与浮游生物图像领域数据表征能力的强耦合性。未执行领域预训练的 ViT-Base 下游任务准确率仅 77.63%，而在基于 MILAN 的 CLIP 辅助语义重建方法完成领域预训练后，其指标提升至 96.40%，凸显了领域预训练在缓解上下游任务分布偏移问题中的核心作用。这一现象表明，预训练通过强化模型对特定数据分布的建模能力，能够有效降低下游任务的优化难度。

而网络模型自身的结构特性也对领域预训练模型的下游任务表现起到明显作用。例如，ConvNeXtV2-tiny 与 Swin-Large 能够凭借层次化设计在局部特征建

模上的优势，分别推动 SparK 和 SimMiM 两种预训练范式突破 96%的下游任务准确率阈值；而 ViT 系列可能受限于全局注意力机制和容量有限的下游任务数据，即使如 HiViT-Large 通过层次化改进将准确率提升至 93.95%，仍逊色于 Swin 架构。而 ViT-Base 在未经过 MILAN 方法进行领域预训练时，在下游任务上所表现出的低性能（77.63%），进一步暴露了 ViT 在有限数据容量下的其全局归纳偏置的脆弱性，尤其容易在数据分布复杂的浮游生物识别任务中显著劣化。这些结果验证了层次化架构在视觉任务中的普适优势，以及 ViT 系列对丰富的训练数据与有效的预训练策略的高度依赖性。在训练效率方面，SimMiM 预训练的 Swin-Base 仅需 100 轮次微调即可达到 96.14%的指标，接近 Swin-Large 的 200 轮次结果（96.22%），表明 Swin 架构的高效收敛特性。相比之下，MAE-ViT-Large 需 200 轮次、SparK 需 300 轮次完成训练，凸显不同范式在计算成本与性能间的权衡需求。这一差异主要由架构适配性和掩码策略的优化程度决定。SparK 采用的 ConvNeXtV2-tiny 与 SimMiM 的 Swin-Large 均基于层次化设计，能够高效地提取局部与全局特征，而基础的 ViT 架构因缺乏局部归纳偏置，需依赖更复杂的训练策略与目标（如 MILAN 的 CLIP 辅助语义重建）或改进架构（如 HiViT-Large）才能较为明显的提升性能。

两种后训练方式的效果不同，进一步反映了各领域预训练模型对浮游生物图像的特征提取与表示能力上所存在的差异。从实验结果来看，全参微调普遍优于线性探针，而两者的差距可能源自于领域预训练的编码器所提取的特征质量。例如，基于 SparK 完成领域预训练后，ConvNeXtV2-tiny 架构在下游任务的两种后训练方式准确率基本相同，表明其编码器特征已接近饱和状态，呈现高度的线性可分性，无需额外参数调整即可适配任务；而 MAE-ViT-Large 的全参微调较线性探针提升 2.02%，反映其自监督目标可能引入与分类任务无关的噪声特征。

4.2.2 多通道特征聚合方法

在领域预训练模型的迁移学习中，特征聚合方法作为连接预训练特征与下游任务的关键环节，其选择直接影响模型对全局或局部特征的利用效率。mmpretrain 框架支持在 ViT 以及 Swin Transformer 骨干网络的训练配置中自行选择不同的多通道特征聚合方法：

1）平均池化（Average Pooling）对所有空间位置（即图像 patch 对应的 token）的特征向量进行逐维度平均，生成全局特征向量。例如，若输出特征为 N×D（N 为 token 数量，D 为特征维度），则平均池化后的特征维度为 1×D 。平均池化倾向于平滑所有局部特征，强调全局统计信息，对噪声和过拟合有一定抑制作用但可能淡化显著区域。其实现简单高效，适用于数据量较小的下游任务（如迁移学习中的低数据域），但容易忽略局部显著特征，可能降低细粒度分类性能。

2）最大池化（Max Pooling）则在每个特征维度上取所有 token 的最大值，生成全局特征向量。例如，对每个维度 d，取所有 N 个 token 中第 d 维的最大值。其能够保留每个通道的最显著响应，适合捕捉突出的局部关键特征，但对噪声相对敏感，可能忽略整体上下文信息。最大池化更适合于依赖局部关键特征的高区分度任务（如存在显著目标的图像分类）。

3）CLS Token：ViT 在输入序列前添加了一个可学习的特殊分类 token（CLS），并且通过 Transformer 的多层自注意力机制与所有 patch token 交互。在下游分类任务的实践中，可仅用 CLS Token 的输出特征作为最终的分类依据。CLS Token 通过自注意力动态聚合全局信息，其表征能力通常依赖于模型对全局关系的建模。CLS Token 能够自适应全局特征融合，理论性能上限高，适用于支持大数据量预训练，且需要建模长距离依赖的任务（如细粒度分类、跨模态对齐），但需充足的数据进行训练，否则更容易欠拟合，增加模型复杂度。

因此，本文进一步对比分析了平均池化、最大池化和 CLS Token 等三种特征聚合方法将提取的特征应用于下游分类任务时的性能表现差异，相应实验指标如表 3 所示。

由上述实验数据可知，平均池化在特征聚合方法的横向对比中普遍更具优势：在基于 MILAN 预训练的 ViT-B 架构的实验中，平均池化的 Top-1 准确率在全参微调和线性探针两种情形下（96.40% / 96.36%）均显著优于最大池化（95.81% / 94.91%）和 CLS_Token（95.92% / 94.95%）。这表明，对于 ViT 架构，全局平均池化能更有效地整合空间维度的特征响应分布，保留浮游生物图像的整体形态信息。而最大池化由于仅提取局部区域的最强激活值，易忽略细粒度特征的空间关联性，导致分类边界模糊。值得注意的是，CLS_Token 作为 ViT 的标准分类头，其性能低于平均池化的现象可能说明，在固定特征提取器的线性探针场景下，由于 DYB-PLANKTONNET 下游任务的训练数据容量有限，通过相对复杂的隐式学习所得到的分类 Token 可能对训练集中特定的数据分布特性产生了过拟合，而显式设计的平均池化聚合方式可能更具鲁棒性。

在 SimMiM（Swin-L/Swin-B 架构）的实验中，平均池化同样保持优势：Swin-L 模型可在 200 轮训练下达到 96.22% / 95.84%（全参微调/线性探针）的准确率，较最大池化（96.04% / 95.64%）也有略微提升；Swin-B 模型在 100 轮训练中，平均池化（96.14% / 95.73%）亦优于最大池化（96.05% / 95.50%），但相较而言差距不大。这一结果表明层次化窗口注意力机制可能与平均池化更为兼容 ——Swin Transformer 通过局部窗口构建多尺度特征，而平均池化可均衡融合各层级的语义信息，而最大池化可能放大浅层高频噪声对深层语义的干扰。此外，由于全参微调允许模型调整底层参数，从而使得分类性能对特征聚合方式的

敏感度降低，因此两类池化方法的差异幅度较线性探针场景更小，从而说明参数可调性能够部分补偿聚合方法的次优选择，同时在参数冻结条件下，特征聚合方法的选择直接影响分类器的判别边界优化：平均池化保留特征图的全局统计特性，其为线性分类层提供的基础特征具有更稳定的协方差矩阵，而最大池化的非线性特征选择机制可能增加分类器拟合难度。

表 3　特征聚合方式对闭集分类任务的影响（%）

预训练范式	网络架构	后训练方式	后训练轮次	特征聚合	准确率 Top-1
MILAN	ViT-B	全参微调	200	平均池化	96.4043
MILAN	ViT-B	全参微调	200	最大池化	95.8115
MILAN	ViT-B	全参微调	200	CLS_Token	95.9282
MILAN	ViT-B	线性探针	200	平均池化	96.3692
MILAN	ViT-B	线性探针	200	最大池化	94.9115
MILAN	ViT-B	线性探针	200	CLS_Token	94.9582
SimMiM	Swin-L	全参微调	200	平均池化	96.2221
SimMiM	Swin-L	全参微调	200	最大池化	96.0468
SimMiM	Swin-L	线性探针	200	平均池化	95.8477
SimMiM	Swin-L	线性探针	200	最大池化	95.6426
SimMiM	Swin-B	全参微调	100	平均池化	96.1446
SimMiM	Swin-B	全参微调	100	最大池化	96.0500
SimMiM	Swin-B	线性探针	100	平均池化	95.7319
SimMiM	Swin-B	线性探针	100	最大池化	95.5088

从特征空间分布的角度分析，平均池化等价于对所提取的浮游生物图像特征的空间维度进行平滑处理，其输出的特征向量具有较低方差，有利于维持类内紧凑性。而最大池化通过抑制非极大值响应，可能破坏特征分布的连续性，导致类间可分性降低。

4.3 开集识别任务

本节的实验基于 2.5 节中所提及的 MSP 方法，继续使用前述的 4 种自监督预训练方式所得到的各模型权重作为特征提取器，在所划分的 DYB-PLANKTONNET 开集识别任务训练集中，使用统一的优化参数配置完成全参微调，最终在对应的测试集和 OoD（分布外）数据集上，通过 MSP 后处理评估模型的 ID 数据识别准确率、OoD 检测性能和模型不确定性。

4.3.1 与现有前沿方法的对比分析

在浮游生物图像识别领域，开集识别能力的提升对于实现真实海洋环境下的可靠监测至关重要。因此，本文选取了目前学界最前沿的三种浮游生物开集识别方法，分别为 Pu 等人的辅助数据增强方法、Ciranni 等人的单类 SVM 检测框架以及 Yang 等人的对比学习检索方案。将上述基线方法与我们所提出的方法在相同的实验设置上所得出的结果进行横向比较，相关结果如表 4 所示。

表 4　本文方案与其他浮游生物图像开集识别算法的性能比较　（%）

实验方法	闭集识别	开集识别				
	准确率 Top-1	AUROC	AUPR	FPR95	AURC	E-AURC
本文方案	95.62	92.36	94.53	43.07	4.16	3.18
Pu	83.35	48.99	88.94	97.51	159.86	146.38
Ciranni	70.83	69.97	76.41	83.85	165.37	117.96
Yang	91.54	86.38	44.46	96.78	29.42	25.83

注：由于 AURC 与 E-AURC 数量级较小，表中展示的为乘以 10^3 后的结果

从实验结果可知，本文提出的基于视觉大模型与自监督预训练的开集识别方案，在闭集分类准确率、分布外检测性能及不确定性量化等核心指标上均显著超越现有主流方法。相较于三种基线方法，本文方案在闭集分类准确率上分别提升 12.27%、24.79%和 4.08%，同时在 AUROC 指标上分别实现 43.37%、22.39%和 5.98 个百分点的增益。这一系统性优势的取得，既源于视觉大模型在参数规模与特征表示能力上的突破，也得益于领域预训练对模型在复杂下游任务上的鲁棒性与泛化性起到的深度优化作用。

一方面，传统方法受限于小模型架构的固有缺陷，难以应对真实海洋环境的复杂性。以 Pu 等人的方法为例，其通过人工构造辅助数据集引入 OoD 样本的弱监督信号，虽在一定程度上缓解了模型对已知类别的过拟合问题，但受限于

ResNet50 等传统 CNN 模型的低维特征空间，其闭集准确率仅为 83.35%，且 AUROC 低至 48.99%。这表明，小型模型有限的参数容量导致其特征空间难以同时满足闭集分类与开集识别的对抗性需求：增强对尾部类别的判别性可能破坏特征分布的连续性，而强制扩大类间距离则加剧了 OoD 样本的误分类风险。而本文方案所采用的视觉大模型，凭借其高维特征空间可以为长尾类别与未知样本预留充足的判别区域，在闭集准确率提升 4.08%的同时，FPR95 指标从 96.78%大幅降至 43.07%，显著降低了特征坍缩与决策边界混淆的风险。

另一方面，本文方法中对领域预训练的引入，从根本上改变了模型对分布偏移与异常样本的响应机制。在传统监督学习框架下，模型的特征表示高度依赖标注数据的分布特性，导致其对训练集外的时空变化敏感。例如，Ciranni 等人的方法，虽尝试通过主成分分析降维与单类 SVM 结合提升检测效率，但其特征提取过程完全依赖 ImageNet-1k 预训练的通用表征，导致分类模型对下游任务的浮游生物图像特有的多尺度纹理与形态特征敏感度不足，最终在 AUPR 指标上仅达到 76.41%，远低于本文方案的 94.53%。而 Yang 等人的对比学习框架虽通过动态参考库增强了模型的环境适应性，但其特征提取器仍受限于 ImageNet-1k 预训练的通用先验知识，导致在面对与标注训练集差异显著海域的浮游生物群落时，性能可能急剧下降。相较于上述方法，本文方案通过掩码自编码器与语义感知采样等预训练策略，可将更接近真实海洋环境分布先验的海量无标注数据中所隐含的领域任务知识嵌入至模型参数中，从而无需依赖大规模标注数据即可完成高质量表征学习，这使得模型在遭遇分布偏移问题时仍能够保持稳定鲁棒的特征提取能力。

综上所述，上述实验结果验证了视觉大模型的特征空间容量能够有效缓解传统方法中小型特征提取器对开闭集多目标优化的制约，以及领域自适应预训练对于通用视觉特征与领域特异性需求间鸿沟的有效缓解作用，领域先验知识的注入对于模型学习长尾类别特征、OoD 样本特征以及随分布偏移高度变异的相关特征的优化作用，从而充分说明了本文方案的有效性。

4.3.2 领域预训练的作用分析

类似地，为了探究领域预训练对于视觉大模型开集任务适应性的提升作用，作为对照组和基线标准，本文同样选取了 4 种预训练范式下，仅在 Imagenet-1K 进行过预训练的对应模型权重，使用完全相同的参数配置完成开集任务的后训练与性能评估。此外，对于经典的 ViT 架构，本文还补充了 Base 模型和 Large 模型在 Imagenet-1K 数据集上直接经过有监督微调（SFT，Supervised Fine-Tuning）的权重参与实验，进一步对比通用有监督预训练、通用自监督预训练和领域预训练的不同效果。若经过领域预训练的模型性能指标，相比于仅 Imagenet-1K 预训

练以及 Imagenet-1K 有监督微调的模型指标有明显增幅，则可以进一步反映出：大规模无标注领域数据集以及领域预训练，对于视觉大模型在海洋浮游生物图像领域的特征提取与表示能力的提升是通用性的，其不仅能够对模拟场景的下游闭集分类任务产生显著增益，更可以有效提升模型在真实海洋环境下部署时所需求的开集识别能力。

针对开集识别任务所得到的指标结果如下，其中，经过领域预训练的实验组结果如表 5 所示，未经过领域预训练的对照组结果如表 6 所示。

实验数据显示，在视觉模型的迁移学习中，领域预训练对下游任务性能的影响非常显著，且呈现出复杂而深刻的内在规律：经过海洋浮游生物领域预训练的模型，相较于其对照组而言，虽然在闭集分类准确率上存在±1.5%左右的波动区间，但其开集识别指标（AUROC 提升 3.8-12.5 个百分点）和不确定性估计指标（E-AURC 降低 0.7-3.5 点）均呈现普遍的系统性优势。这一现象充分揭示了模型的特征表示能力与任务适应性的深刻关联：当模型在领域预训练中学习到质量更高且更为鲁棒的特征表示时，其分类决策边界可能发生显著的结构性变化。虽然模型对特定闭集任务的局部最优解可能产生轻微的偏移，但整体特征空间的拓扑结构得到了优化，从而增强了对分布偏移的鲁棒性，使得模型能够更好地适应真实海洋环境下更为复杂的浮游生物开集识别任务。

从表示学习的视角分析，个别未经过领域预训练的模型，在闭集任务上取得相对更好的性能表现，而在开集任务的对应指标上却逊于领域预训练模型，可能源于 ImageNet-1k 数据集中通用图像特征与浮游生物领域图像特征的巨大域间差异。以对照组的 MILAN 模型为例，其 95.25%的闭集准确率虽高于领域预训练模型的 94.03%，但在通用特征的支撑下，对于相对复杂、域间差异明显且具有领域特点的浮游生物图像特征，可能形成过于锐化的决策边界。而这种锐化过程，在 DYB-PLANKTONNET 训练集相对有限的样本容量下，更容易捕获数据集的特异性噪声而形成过拟合，导致模型对 ID 样本的细微变化过度敏感。当模型进入更为复杂的开集识别场景并遭遇 OoD 样本时，相对锐化的决策边界会进一步放大分类决策的敏感性，仅 FPR95 指标即恶化至 63.05%，较领域预训练模型高出 8.41 个百分点。

表 5　实验组：经过领域预训练后得到视觉大模型的开集识别指标（%）

预训练范式	网络架构	闭集识别	开集识别				
		Acc Top-1	AUROC	AUPR	FPR95	AURC	E-AURC
SparK	ConvNeXt V2-tiny	94.27	82.40	88.94	55.65	7.71	6.04
MAE	ViT-L	93.61	86.90	91.37	53.69	7.44	5.36
MAE	HiViT-B	95.45	87.39	92.03	48.94	4.99	3.94
MILAN	ViT-B	94.03	86.60	91.09	54.64	7.90	6.08
SimMIM	Swin-L	95.62	92.36	94.53	43.07	4.16	3.18
SimMIM	Swin-B	95.43	82.53	89.54	51.49	5.98	4.92

注：由于 AURC 与 E-AURC 数量级较小，表中展示的为乘以 10^3 后的结果

表 6　对照组：未经领域预训练的视觉大模型的开集识别指标（%）

预训练范式	网络架构	闭集识别	开集识别				
		Acc Top-1	AUROC	AUPR	FPR95	AURC	E-AURC
SparK	ConvNeXt V2-tiny	95.72	77.87	86.63	57.88	8.07	7.14
SFT	ViT-L	91.88	87.69	90.80	60.77	9.77	6.38
MAE	HiViT-B	93.22	74.87	83.97	68.49	9.80	7.45
MILAN	ViT-B	95.25	75.15	84.86	63.05	8.49	7.35
SFT	ViT-B	92.22	85.46	89.84	63.10	10.40	7.30
SimMIM	Swin-L	95.52	82.76	89.32	52.26	7.73	6.71
SimMIM	Swin-B	95.52	81.73	88.83	53.08	7.57	6.55

注：由于 AURC 与 E-AURC 数量级较小，表中展示的为乘以 10^3 后的结果

而部分模型在经过领域预训练后，呈现出全面的性能提升，揭示了模型架构与预训练范式的协同优化效应。以 HiViT-B 为例，该模型在进行 MAE 领域预训练后，不仅在闭集准确率上提升 2.23%，同时 AUROC 从 74.87% 跃升至 87.39%，提高了 12.52 个百分点，而 AUROC 和 FPR95 等指标也分别提升 8.06% 和 19.55%，效果非常显著，验证了领域知识注入能有效拓宽模型的特征表示能力——即使该过程没有强监督信号的辅助。而这种全方位的优化效果，可能源于层次化视觉 Transformer（HiViT）的渐进式特征提取机制与 MAE 预训练范式的良好耦合：其中，MAE 的像素级重建任务，能够迫使模型建立细粒度特征关联，而 HiViT 的跨阶段特征融合机制，则增强了图像特征中语义信息的层次化表达。当这种组合应用于海洋浮游生物这类具有复杂形态特征的领域时，模型不仅能捕捉浮游生物的组织纹理等局部特征，还能建立生物整体形态与分类标签的稳健关联。

从模型优化的角度考察，领域预训练实质上改变了模型参数的初始化分布。传统 ImageNet-1k 预训练形成的参数先验更偏向通用物体的识别，而领域预训练建立的先验分布，则包含了浮游生物图像特征的领域特异性偏置。这种偏置在微调过程中能够引导优化轨迹向鲁棒性更高的区域移动，进而在优化过程中提升模型对分布偏移的稳定性。尽管闭集准确率相较于对照组结果出现轻微波动，但领域预训练模型在开集任务上的取得性能表现显著优于通用预训练下直接微调的模型。

同时，模型不确定性指标的改善，补充佐证了领域预训练对模型所提取特征的置信度的提升作用。在 HiViT-B 模型中，基于 MAE 的领域预训练使 E-AURC 从 7.45 降至 3.94，降幅达 47.1%。这种提升可能源于领域预训练过程中所建立的特征在可分性上的显著增强：当模型在预训练阶段接触大量无标注领域数据时，其置信度评分函数逐渐适应特征空间的真实分布形态。相较于基于浮游生物专家通过人工挑选和标注所构建的 DYB-PLANKTONNET 数据集，更接近真实海洋环境浮游生物分布特点的大型无标注领域数据集，继承了现实场景中可能存在的干扰因素，例如光照折射、水体浑浊、形态变异、域外样本等，而这些因素所具备的特征能够在领域预训练中系统性地为模型所捕捉和学习到，进而使得模型经过混合学习策略的指引完成下游任务训练后，最终可以有效识别并处理低置信度的样本。

然而值得注意的是，跨模型对比实验的结果，揭示了在目前基于 DYB-PLANKTONNET 所模拟的开集识别任务场景中，模型参数规模可能并非影响模型能力的决定性因素。对于 Swin Transformer 系列模型中，Swin-L 架构在 SimMIM 预训练下取得 95.52%的闭集准确率，仅较 Swin-B 模型提升 0.09%，且其开集识别优势（FPR95 52.26% vs 53.08%）也并不显著。即使对比不同架构的

模型，ConvNeXtV2-tiny，ViT-Base 等模型也均能够在恰当合适的预训练框架下表现出不逊色于 ViT-L、Swin-L 等大型视觉模型的表现。这种现象可能既源于大型架构的过参数化特性（即当模型参数规模超过特定阈值时，额外的参数更倾向于记忆训练数据细节，而非学习普适性特征），同时也和 DYB-PLANKTONNET 相对有限的标注数据容量有关，使得大模型的参数规模在 Scaling-Law 中所总结的经验性优势难以得到充分发挥。

第 5 章 结论与展望

随着人工智能技术的快速发展，深度学习为海洋浮游生物图像识别领域带来了革命性突破。本文重点围绕浮游生物图像分类中存在的分布不平衡与异常分布（OoD）检测等核心挑战，系统性地探索了目前流行的视觉大模型与自监督预训练范式在闭集与开集任务中的性能表现，从而相对成功地完成了视觉大模型以及大规模自监督学习方法在海洋浮游生物图像识别领域应用中的技术迁移。本文通过对比分析多种视觉预训练框架（MAE、SparK、SimMIM、MILAN）在不同的现代神经网络架构（ViT、Swin Transformer、ConvNeXtV2）下的迁移学习效果，并结合闭集分类和开集识别的实验验证，揭示了领域预训练对模型在浮游生物图像特征的表示能力与鲁棒性上具备显著的提升作用。研究结果表明，基于大规模无标注浮游生物图像数据的自监督预训练，能够有效缓解通用视觉任务和浮游生物原位图像识别之间存在的域间分布差异，增强视觉大模型对真实海洋环境动态变化的适应性，为浮游生物监测技术的智能化发展提供了重要理论支撑与实践参考。

研究充分体现了视觉大模型在参数规模与层次化特征表示能力上的核心优势，为破解浮游生物图像识别的固有难题提供了全新范式。相较于传统小型 CNN 模型有限的参数容量，以 ViT、Swin Transformer 和 ConvNeXtV2 为代表的视觉大模型，通过自注意力机制、稀疏卷积与多尺度特征融合等设计，构建了高维、解耦的特征空间。这种高容量特征空间能够有效缓解闭集分类与开集识别之间的优化冲突：一方面，其层次化语义提取机制可同时捕获浮游生物图像的全局形态关联与局部细粒度特征，从而强化对长尾类别微观差异的判别性；另一方面，庞大的参数规模为未知类别预留了充足的判别区域，显著降低 OoD 样本被误分类为已知类别的风险。值得注意的是，这种性能提升并非单纯源于参数规模的量级优势，而是源自大模型架构与自监督预训练范式的深度耦合。

在闭集多分类任务中，领域预训练展现出其对于视觉大模型普适性的性能增益。实验数据显示，基于浮游生物图像数据进行领域预训练的视觉大模型，其下游分类准确率较 ResNet50 等传统方案中所使用的小模型，可实现接近 2%的显著提升，且相较于仅使用 ImageNet 预训练的对照组，提升最高可达 18.77%（如 MILAN-ViT-B 模型从 77.63%提升至 96.40%）。这一现象验证了领域数据与自监督目标的协同效应：通过掩码图像建模、对比学习等策略，模型能够从海量无标注数据中挖掘浮游生物的形态、纹理与空间分布特征，从而建立更具判别性的特征空间。值得注意的是，不同预训练范式与网络架构的适配性差异显著影响最终性能。例如，SparK 框架在 ConvNeXtV2-tiny 架构下通过稀疏卷积与层次化建模

实现了 96.07%的闭集准确率，而 SimMIM 在 Swin-Large 架构中凭借极简掩码策略与像素级重建任务达到了 96.22%，而 MILAN 通过 CLIP 语义辅助重建的方法更是取得了 96.40%的顶尖水平。这些结果表明，视觉大模型的成功不仅依赖于自身结构和机制的优秀设计，更需结合创新性的预训练范式以充分捕捉浮游生物的多尺度及语义特征。

开集识别实验则揭示了领域预训练对模型不确定性与 OoD 检测能力的深层优化。即使仅基于 MSP 的简单后处理方法实现 OoD 检测，相对于未进行领域预训练的基线结果，各预训练模型在分布外样本检测与低置信度样本拒识等指标上均取得显著突破。这一现象表明，领域预训练通过增强特征空间的类内紧致性与类间可分性，能够有效抑制模型对噪声与异常样本的过度自信。例如，HiViT-B 模型在 MAE 预训练后，其 FPR95 从 68.49%降至 48.94%，验证了领域预训练中像素级重建任务对学习图像细粒度特征的强化作用。值得注意的是，模型参数规模与性能提升并非线性相关，Swin-Base 与 ConvNeXtV2-tiny 等相对轻量的架构在适配性优化后同样能够达到与大型模型相近的性能，这为边缘计算场景下的浮游生物实时开集监测提供了可行性依据。然而，研究也发现，闭集准确率的轻微波动可能源于领域预训练对决策边界的结构性调整，这种调整虽降低了模型对训练集过拟合的风险，但也需通过更精细的损失函数超参数调整以平衡闭集与开集任务的优化目标。

尽管本研究取得了重要进展，但仍存在若干尚未解决的局限性问题。首先，当前实验中所使用的大规模私有无标注数据集，仅仅是从海量的浮游生物原位图像池中所随机挑选的而构建完成的，其质量既未经过相关的数据分析方法进行详细评估，也未通过相应的数据清洗和挖掘策略优化其质量，而领域预训练的有效性和下游任务性能都高度依赖于高质量的样本数据。因此，如何进一步构建相应的高效数据挖掘算法，从而能够向上游的领域预训练任务提供大规模且高质量的浮游生物原位图像数据集，将是进一步发挥领域预训练作用的重要课题。同时，本文研究所涉及的实验主要基于静态数据集展开，未能充分模拟真实海洋环境中浮游生物群落的时空动态变化，因此，未来的研究可能需要进一步引入相关的时序建模与在线学习机制，以应对浮游生物季节性迁移与突发性生态事件带来的分布漂移问题。其次，由于视觉大模型的上下游全链路训练耗费了高昂的时间成本、硬件存储和算力资源，本研究受制于有限的计算资源和高度紧迫的时间周期，在实验设计上无法支持对各视觉大模型在上游领域预训练和下游任务微调时的最佳超参数组合进行充分探索，考虑到大模型参数调优实践的复杂性，本文所呈现的实验结果，可能还局限于相对次优的结果，并未能够充分展现大模型的真实潜力和优势。同时，视觉大模型较长的训练迭代周期，使得本研究难以分配足够的

时间资源，对模型的特征空间性质、特征质量、鲁棒性等设计完备的统计检验并进行系统性实验和分析，故相关理论层面的分析工作还有待后续研究进一步完善。

此外，多模态融合技术已经在自动驾驶等多个应用领域展现出解决开集场景目标识别的强大能力，但在海洋浮游生物图像识别领域的潜力还尚未被充分挖掘。早期的 CLIP，以及最新的 YOLO-World，DINO-X，Qwen-VL 等多模态大模型模型已充分证明跨模态对齐对于视觉语义表征的增强作用，但如何将其与浮游生物领域知识（如物种生态位、生理特性、分子生物学信息等）相结合，仍需进一步探索。例如，通过引入专家标注的文本描述或环境参数，构建多模态对比学习框架，有望提升模型对复杂生物特征的解耦能力。而本文提供的领域预训练方法，可以向跨模态对齐学习提供具备海洋浮游生物原位图像先验知识的视觉编码器，为该领域的多模态识别方案提供助力和支撑。

在本研究的基础之上，视觉大模型与自监督学习技术的深度融合将持续推动浮游生物识别领域的范式革新。一方面，基于稀疏计算、量化推理与知识蒸馏的模型轻量化技术，将进一步拓展视觉大模型在浮标、无人艇等边缘设备的部署可行性，实现原位数据的实时处理与反馈。另一方面，结合物理启发的生成式模型（如扩散模型），可通过模拟不同光照、浊度与深度条件下的浮游生物成像过程，构建更具泛化性的增强数据集，从而突破真实数据采集的成本限制。同时，开放集识别框架的优化，还有进一步向可解释性与可靠性纵深发展的潜力，通过引入不确定性量化与证据推理机制，结合跨模态语义信息，能够使模型能够为分类决策提供置信度评估与生物学依据，进而辅助海洋浮游生物学家进行更精准可靠的物种鉴定与生态评估。最终，这些技术进步将推动浮游生物监测从传统的离线人工分析向高度在线化、智能化的端到端感知系统跃迁，为全球气候变化研究、赤潮预警与生物多样性保护提供强有力的技术支撑。

参考文献

[1] Arrigo K R, 2005. Marine microorganisms and global nutrient cycles[J]. Nature, 437(7057) : 349 – 355.

[2] Azam F, Fenchel T, Field J G, et al., 1983. The ecological role of water-column microbes in the sea[J]. Marine Ecology Progress Series. Oldendorf, 10(3) : 257 – 263.

[3] Falkowski P, 2012. Ocean science: The power of plankton[J]. Nature, 483(7387) : S17 – S20.

[4] Hays G C, Richardson A J, Robinson C, 2005. Climate change and marine plankton[J]. Trends in Ecology & Evolution, 20(6) : 337 – 344.

[5] Piredda R, Tomasino M P, D'Erchia A, et al., 2017. Diversity and temporal patterns of planktonic protist assemblages at a Mediterranean long-term ecological research site[J]. FEMS Microbiology Ecology, 93(1) : fiw200.

[6] Hallegraeff G M, 1988. Plankton: A microscopic world[M]. Brill Archive.

[7] Ballón M, Bertrand A, Lebourges-Dhaussy A, et al., 2011. Is there enough zooplankton to feed forage fish populations off Peru? An acoustic (positive) answer[J]. Progress in Oceanography, 91(4) : 360 – 381.

[8] Cheriton O M, McManus M A, Holliday D, et al., 2007. Effects of mesoscale physical processes on thin zooplankton layers at four sites along the west coast of the US[J]. Estuaries and Coasts, 30: 575 – 590.

[9] Gardner W D, Richardson M J, Mishonov A V, et al., 2018. Global comparison of benthic nepheloid layers based on 52 years of nephelometer and transmissometer measurements[J]. Progress in Oceanography, 168: 100 – 111.

[10] Lombard F, Boss E, Waite A M, et al., 2019. Globally consistent quantitative observations of planktonic ecosystems[J]. Frontiers in Marine Science, 6: 196.

[11] MacIntyre H L, Lawrenz E, Richardson T L, 2010. Taxonomic discrimination of phytoplankton by spectral fluorescence[C]. In: Chlorophyll a Fluorescence in Aquatic Sciences: Methods and Applications, pp. 129 – 169.

[12] MacLennan D N, Simmonds E J, 2013. Fisheries Acoustics, vol. 5[M]. Springer Science & Business Media.

[13] Shapiro H M, 2005. Practical Flow Cytometry[M]. John Wiley & Sons.

[14] Barteneva N S, Fasler-Kan E, Vorobjev I A, 2012. Imaging flow cytometry: Coping with heterogeneity in biological systems[J]. Journal of Histochemistry & Cytochemistry, 60(10) : 723 – 733.

[15] Benfield M C, Grosjean P, Culverhouse P F, et al., 2007. RAPID research on automated plankton identification[J]. Oceanography, 20: 172 – 187.

[16] Irisson J O, Ayata S D, Lindsay D J, et al., 2021. Machine learning for the study of plankton and marine snow from images[J]. Annual Review of Marine Science, 14: 277 – 301.

[17] MacLeod N, Benfield M, Culverhouse P, 2010. Time to automate identification[J]. Nature, 467: 154 – 155.

[18] Corgnati L, Marini S, Mazzei L, et al., 2016. Looking inside the ocean: Toward an autonomous imaging system for monitoring gelatinous zooplankton[J]. Sensors, 16(12) : 2124.

[19] Ellen J, Li H, Ohman M D, 2015. Quantifying California current plankton samples with efficient machine learning techniques[C]. In: OCEANS 2015 - MTS/IEEE Washington, pp. 1 – 9.

[20] Mosleh M A A, Manssor H, Malek S, et al., 2012. A preliminary study on automated freshwater algae recognition and classification system[J]. BMC Bioinformatics, 13: 1 – 13.

[21] Rivas-Villar D, Rouco J, Carballeira R, et al., 2021. Fully automatic detection and classification of phytoplankton specimens in digital microscopy images[J]. Computer Methods and Programs in Biomedicine, 200: 105923.

[22] Sosik H M, Olson R J, 2007. Automated taxonomic classification of phytoplankton sampled with imaging-in-flow cytometry[J]. Limnology and Oceanography: Methods, 5(6) : 204 – 216.

[23] Zhou J, Wei C, Wang H, et al., 2023. Image BERT Pre-training with Online Tokenizer[C]. In: International Conference on Learning Representations.

[24] Brown T, Mann B, Ryder N, et al., 2020. Language models are few-shot learners[C]. In: Advances in Neural Information Processing Systems, vol. 33, pp. 1877 – 1901.

[25] Ho T K, 1995. Random decision forests[C]. In: Proceedings of 3rd international conference on document analysis and recognition, vol. 1, pp. 278 – 282. IEEE.

[26] Bochinski E, Bacha G, Eiselein V, et al., 2018. Deep active learning for In situ plankton classification[C]. In: International Conference on Pattern Recognition, pp. 5 – 15. Springer International Publishing, Cham.

[27] Lee H, Park M, Kim J, 2016. Plankton classification on imbalanced large scale database via convolutional neural networks with transfer learning[C]. In: 2016 IEEE international conference on image processing (ICIP) , pp. 3713 – 3717. IEEE, Phoenix, AZ, USA.

[28] Li X, Cui Z, 2016. Deep residual networks for plankton classification[C]. In: OCEANS 2016 MTS/IEEE Monterey, pp. 1 – 4. IEEE, Monterey, CA, USA.

[29] Luo J Y, Irisson J O, Graham B, et al., 2018. Automated plankton image analysis using convolutional neural networks[J]. Limnology and Oceanography: Methods, 16(12) : 814 – 827.

[30] Pedraza A, Bueno G, Deniz O, et al., 2017. Automated diatom classification (Part B) : a deep

learning approach[J]. Applied Sciences, 7: 460.

[31] Bi H, Cook S, Yu H, et al., 2013. Deployment of an imaging system to investigate fine-scale spatial distribution of early life stages of the ctenophore Mnemiopsis leidyi in Chesapeake Bay[J]. Journal of Plankton Research, 35: 270 – 280.

[32] Giering S L C, Cavan E L, Basedow S L, et al., 2020. Sinking organic particles in the ocean—flux estimates from in situ optical devices[J]. Frontiers in Marine Science, 6: 834.

[33] Guo J, Ma Y, Lee J H, 2021. Real-time automated identification of algal bloom species for fisheries management in subtropical coastal waters[J]. Journal of Hydro-environment Research, 36: 1 – 32.

[34] Henrichs D W, Angles S, Gaonkar C C, et al., 2021. Application of a convolutional neural network to improve automated early warning of harmful algal blooms[J]. Environmental Science and Pollution Research, 28: 28544 – 28555.

[35] Pitois S G, Graves C A, Close H, et al., 2021. A first approach to build and test the Copepod Mean Size and Total Abundance (CMSTA) ecological indicator using in-situ size measurements from the Plankton Image (PI) [J]. Ecological Indicators, 123: 107307.

[36] Romagnan J B, Aldamman L, Gasparini S, et al., 2016. High-frequency mesozooplankton monitoring: Can imaging systems and automated sample analysis help us describe and interpret changes in zooplankton community composition and size structure—an example from a coastal site[J]. Journal of Marine Systems, 162: 18 – 28.

[37] Song J, Bi H, Cai Z, et al., 2020. Early warning of Noctiluca scintillans blooms using in situ plankton imaging system: an example from Dapeng Bay, P.R. China[J]. Ecological Indicators, 112: 106123.

[38] Taucher J, Stange P, Alguero-Muniz M, et al., 2018. In situ camera observations reveal major role of zooplankton in modulating marine snow formation during an upwelling-induced plankton bloom[J]. Progress in Oceanography, 164: 75 – 88.

[39] Gu J, Wang Z, Kuen J, et al., 2018. Recent advances in convolutional neural networks[J]. Pattern Recognition, 77: 354 – 377.

[40] Mitra R, Marchitto T M, Ge Q, et al., 2019. Automated species-level identification of planktic foraminifera using convolutional neural networks, with comparison to human performance[J]. Marine Micropaleontology, 147: 16 – 24.

[41] Zheng H, Wang R, Yu Z, et al., 2017. Automatic plankton image classification combining multiple view features via multiple kernel learning[J]. BMC Bioinformatics, 18: 1 – 18.

[42] Moreno-Torres J G, Raeder T, Alaiz-Rodríguez R, et al., 2012. A unifying view on dataset shift in classification[J]. Pattern Recognition, 45: 521–530.

[43] González P, Castaño A, Peacock E E, et al., 2019. Automatic plankton quantification using deep features[J]. Journal of Plankton Research, 41: 449–463.

[44] Yang J, Zhou K, Li Y, et al., 2024. Generalized out-of-distribution detection: A survey[J]. International Journal of Computer Vision, 132(12): 5635–5662.

[45] Walker J L, Orenstein E C, 2021. Improving rare-class recognition of marine plankton with hard negative mining[C]. In: Proceedings of the IEEE/CVF International Conference on Computer Vision, pp. 3672–3682. IEEE, Montreal, BC, Canada.

[46] González P, Álvarez E, Díez J, et al., 2017. Validation methods for plankton image classification systems[J]. Limnology and Oceanography: Methods, 15: 221–237.

[47] Liu Z, Hu H, Lin Y, et al., 2022. Swin transformer v2: Scaling up capacity and resolution[C]. In: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, pp. 12009–12019.

[48] Liu Z, Lin Y, Cao Y, et al., 2021. Swin Transformer: Hierarchical vision transformer using shifted windows[C]. In: Proceedings of the IEEE/CVF International Conference on Computer Vision, pp. 10012–10022.

[49] Dosovitskiy A, Beyer L, Kolesnikov A, et al., 2021. An image is worth 16x16 words: Transformers for image recognition at scale[C]. In: Proceedings of the International Conference on Learning Representations (ICLR) .

[50] Orenstein E C, Beijbom O, 2017. Transfer learning and deep feature extraction for planktonic image data sets[C]. In: 2017 IEEE Winter Conference on Applications of Computer Vision (WACV) , pp. 1082–1088. IEEE, Santa Rosa, CA, USA.

[51] Khan S H, Hayat M, Bennamoun M, et al., 2017. Cost-sensitive learning of deep feature representations from imbalanced data[J]. IEEE Transactions on Neural Networks and Learning Systems, 29: 3573–3587.

[52] Li J, Chen T, Yang Z, et al., 2022. Development of a buoy-borne underwater imaging system for In situ mesoplankton monitoring of coastal waters[J]. IEEE Journal of Oceanic Engineering, 47: 88–110.

[53] Plonus R M, Conradt J, Harmer A, et al., 2021. Automatic plankton image classification—can capsules and filters help cope with data set shift?[J]. Limnology and Oceanography: Methods, 19: 176–195.

[54] Pu Y, Feng Z, Wang Z, et al., 2021. Anomaly detection for in situ marine plankton images[C]. In: Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV) Workshops, pp. 3661–3671.

[55] Rawat W, Wang Z, 2017. Deep convolutional neural networks for image classification: a

comprehensive review[J]. Neural Computation, 29: 2352–2449.

[56] Li J, Yang Z, Chen T, 2021. DYB-PlanktonNet[J]. IEEE Dataport.

[57] Caron M, Touvron H, Misra I, et al., 2021. Emerging properties in self-supervised vision transformers[C]. In: Proceedings of the IEEE/CVF International Conference on Computer Vision, pp. 9650–9660.

[58] Yang Z, Li J, Chen T, et al., 2022. Contrastive learning-based image retrieval for automatic recognition of in situ marine plankton images[J]. ICES Journal of Marine Science, 79(10) : 2643–2655.

[59] Ciranni M, Odone F, Pastore V P, 2024. Anomaly detection in feature space for detecting changes in phytoplankton populations[J]. Frontiers in Marine Science, 10: 1283265.

[60] He K, Chen X, Xie S, et al., 2022. Masked autoencoders are scalable vision learners[C]. In: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR) , pp. 16000 – 16009.

[61] Tian K, Jiang Y, Lin C, et al., 2023. Designing BERT for Convolutional Networks: Sparse and Hierarchical Masked Modeling[C]. In: The Eleventh International Conference on Learning Representations.

[62] Xie Z, Zhang Z, Cao Y, et al., 2022. Simmim: A simple framework for masked image modeling[C]. In: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, pp. 9653 – 9663.

[63] Hou Z, Sun F, Chen Y K, et al., 2022. Milan: Masked image pretraining on language assisted representation[J]. arXiv preprint arXiv:2208.06049.

[64] Liu Z, Mao H, Wu C-Y, et al., 2022. A convnet for the 2020s[C]. In: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, pp. 11976 – 11986.

[65] Hendrycks D, Gimpel K, 2017. A Baseline for Detecting Misclassified and Out-of-Distribution Examples in Neural Networks[C]. In: International Conference on Learning Representations.

[66] Bengio Y, 2012. Deep learning of representations for unsupervised and transfer learning[C]. In: Proceedings of ICML Workshop on Unsupervised and Transfer Learning, pages 17 – 36.

[67] Devlin J, Chang M W, Lee K, et al., 2019. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding[C]. In: Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (NAACL) , pp. 4171 – 4186.

[68] Donahue J, Jia Y, Vinyals O, et al., 2014. DeCAF: A deep convolutional activation feature for generic visual recognition[C]. In: International Conference on Machine Learning, pages 647 –

655.

[69] Erhan D, Bengio Y, Courville A, et al., 2010. Why does unsupervised pre-training help deep learning?[J]. Journal of Machine Learning Research, 11(Feb) : 625 – 660.

[70] Goodfellow I, Bengio Y, Courville A, 2016. Deep learning[M]. MIT Press.

[71] Gururangan S, Marasovic A, Swayamdipta S, et al., 2020. Don't stop pretraining: Adapt language models to domains and tasks[C]. In: 58th Annual Meeting of the Association for Computational Linguistics, ACL 2020, pp. 8342 – 8360. Association for Computational Linguistics (ACL).

[72] He K, Gkioxari G, Dollár P, et al., 2017. Mask R-CNN[C]. In: Proceedings of the IEEE International Conference on Computer Vision, pages 2961 – 2969.

[73] Lamm N, Jaiprakash S, Srikanth M, et al., 2020. Vehicle trajectory prediction by transfer learning of semi-supervised models[J]. arXiv preprint arXiv:2007.06781.

[74] Pfeiffer J, Rücklé A, Poth C, et al., 2020. AdapterHub: A framework for adapting transformers[C]. In: Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing: System Demonstrations, pages 46 – 54.

[75] Puigcerver J, Ruiz C R, Mustafa B, et al., 2023. Scalable Transfer Learning with Expert Models[C]. In: International Conference on Learning Representations.

[76] Radford A, Narasimhan K, Salimans T, et al., 2018. Improving language understanding by generative pre-training[J].

[77] Yalniz I Z, Jégou H, Chen K, et al., 2019. Billion-scale semi-supervised learning for image classification[J]. arXiv preprint arXiv:1905.00546.

[78] Wu Z, Xiong Y, Yu S X, et al., 2018. Unsupervised feature learning via non-parametric instance discrimination[C]. In: Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, pages 3733 – 3742.

[79] Deng J, Dong W, Socher R, et al., 2009. ImageNet: A large-scale hierarchical image database[C]. In: Proceedings of CVPR, pp. 248 – 255.

[80] Russakovsky O, Deng J, Su H, et al., 2015. ImageNet Large Scale Visual Recognition Challenge[J]. International Journal of Computer Vision, 115: 211 – 252.

[81] Liu X, Zhang F, Hou Z, et al., 2021. Self-supervised learning: Generative or contrastive[J]. IEEE Transactions on Knowledge and Data Engineering, 35(1): 857 – 876.

[82] Ngiam J, Peng D, Vasudevan V, et al., 2018. Domain adaptive transfer learning with specialist models[J]. arXiv preprint arXiv:1811.07056.

[83] Quattoni A, Collins M, Darrell T, 2008. Transfer learning for image classification with sparse prototype representations[C]. In: 2008 IEEE Conference on Computer Vision and Pattern

Recognition, pages 1 – 8.

[84] Peng X, Bai Q, Xia X, et al., 2019. Moment matching for multi-source domain adaptation[C]. In: Proceedings of the IEEE International Conference on Computer Vision, pages 1406 – 1415.

[85] Neumann M, Pinto A S, Zhai X, et al., 2019. In-domain representation learning for remote sensing[J]. arXiv preprint arXiv:1911.06721.

[86] Caron M, Misra I, Mairal J, et al., 2020. Unsupervised learning of visual features by contrasting cluster assignments[C]. In: Thirty-fourth Conference on Neural Information Processing Systems (NeurIPS) .

[87] Chen M, Radford A, Child R, et al., 2020. Generative pretraining from pixels[J]. Advances in Neural Information Processing Systems.

[88] Chen T, Kornblith S, Norouzi M, et al., 2020. A simple framework for contrastive learning of visual representations[C]. In: International Conference on Machine Learning, pp. 1597 – 1607. PMLR.

[89] Cheng G, Han J, Lu X, 2017. Remote sensing image scene classification: Benchmark and state of the art[J]. Proceedings of the IEEE, 105(10) : 1865–1883.

[90] Doersch C, Gupta A, Efros A A, 2015. Unsupervised visual representation learning by context prediction[C]. In: Proceedings of the IEEE International Conference on Computer Vision (ICCV) , pp. 1422 – 1430.

[91] Noroozi M, Favaro P, 2016. Unsupervised learning of visual representations by solving jigsaw puzzles[C]. In: Proceedings of the European Conference on Computer Vision (ECCV) , pp. 69 – 84.

[92] Wang X, Gupta A, 2015. Unsupervised learning of visual representations using videos[C]. In: Proceedings of the IEEE International Conference on Computer Vision (ICCV) , pp. 2794 – 2802.

[93] Pathak D, Girshick R, Dollár P, et al., 2017. Learning features by watching objects move[C]. In: Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR) , pp. 2701 – 2710.

[94] Zhang R, Isola P, Efros A A, 2016. Colorful image colorization[C]. In: Proceedings of the European Conference on Computer Vision (ECCV) , pp. 649 – 666.

[95] Gidaris S, Singh P, Komodakis N, 2018. Unsupervised representation learning by predicting image rotations[C]. In: Proceedings of the International Conference on Learning Representations (ICLR) .

[96] Dosovitskiy A, Fischer P, Springenberg J T, et al., 2015. Discriminative unsupervised feature learning with exemplar convolutional neural networks[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 38(9) : 1734 – 1747.

[97] He K, Fan H, Wu Y, et al., 2020. Momentum contrast for unsupervised visual representation learning[C]. In: Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition.

[98] Reed C J, Metzger S, Srinivas A, et al., 2021. SelfAugment: Automatic augmentation policies for self-supervised learning[C]. In: Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition.

[99] Xiao T, Wang X, Efros A A, et al., 2023. What Should Not Be Contrastive in Contrastive Learning[C]. In: International Conference on Learning Representations.

[100] Niu S, Liu M, Liu Y, et al., 2021. Distant domain transfer learning for medical imaging[J]. IEEE Journal of Biomedical and Health Informatics, 25(10): 3784 – 3793.

[101] Raghu M, Zhang C, Kleinberg J, et al., 2019. Transfusion: Understanding transfer learning for medical imaging[J]. Advances in Neural Information Processing Systems, 32.

[102] Clark K, Luong M-T, Le Q V, et al., 2020. ELECTRA: Pre-training Text Encoders as Discriminators Rather Than Generators[C]. In: International Conference on Learning Representations.

[103] Dong L, Yang N, Wang W, et al., 2019. Unified language model pre-training for natural language understanding and generation[C]. In: Advances in Neural Information Processing Systems, vol. 32.

[104] Radford A, Narasimhan K, Salimans T, et al., 2018. Improving language understanding by generative pre-training[J].

[105] Chen X, Ding M, Wang X, et al., 2024. Context autoencoder for self-supervised representation learning[J]. International Journal of Computer Vision, 132(1): 208–223.

[106] Bao H, Dong L, Piao S, et al., 2022. BEiT: BERT Pre-Training of Image Transformers[C]. In: International Conference on Learning Representations.

[107] Chen X, Xie S, He K, 2021. An empirical study of training self-supervised vision transformers[C]. In: Proceedings of the IEEE/CVF International Conference on Computer Vision, pp. 9640 – 9649.

[108] Grill J-B, Strub F, Altché F, et al., 2020. Bootstrap your own latent: A new approach to self-supervised learning[C]. In: Advances in Neural Information Processing Systems, vol. 33, pp. 21271 – 21284.

[109] Pathak D, Krahenbuhl P, Donahue J, et al., 2016. Context encoders: Feature learning by inpainting[C]. In: Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, pp. 2536 – 2544.

[110] Zhang R, Isola P, Efros A A, 2017. Split-brain autoencoders: Unsupervised learning by

cross-channel prediction[C]. In: Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, pp. 1058 – 1067.

[111] Fang Y, Dong L, Bao H, et al., 2023. Corrupted Image Modeling for Self-Supervised Visual Pre-Training[C]. In: The Eleventh International Conference on Learning Representations.

[112] Gao P, Ma T, Li H, et al., 2022. ConvMAE: Masked convolution meets masked autoencoders[J]. arXiv preprint arXiv:2205.03892.

[113] Bateman J A, 2014. Text and image: A critical introduction to the visual/verbal divide[M]. Routledge.

[114] Bay H, Tuytelaars T, Van Gool L, 2006. SURF: Speeded Up Robust Features[C]. In: European Conference on Computer Vision, pp. 404 – 417.

[115] Lowe D G, 1999. Object recognition from local scale-invariant features[C]. In: Proceedings of the Seventh IEEE International Conference on Computer Vision, vol. 2, pp. 1150 – 1157.

[116] Lin T-Y, Dollar P, Girshick R, et al., 2017. Feature pyramid networks for object detection[C]. In: Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR) .

[117] He K, Zhang X, Ren S, et al., 2015. Spatial pyramid pooling in deep convolutional networks for visual recognition[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 37(9) : 1904 – 1916.

[118] Graham B, van der Maaten L, 2017. Submanifold sparse convolutional networks[J]. arXiv preprint arXiv:1706.01307.

[119] Hubel D H, Wiesel T N, 1962. Receptive fields, binocular interaction and functional architecture in the cat's visual cortex[J]. The Journal of Physiology, 160(1) : 106–154.

[120] Radford A, Kim J W, Hallacy C, et al., 2021. Learning transferable visual models from natural language supervision[C]. In: Proceedings of the International Conference on Machine Learning, pages 8748–8763.

[121] Yu B X B, Chang J, Wang H, et al., 2024. Visual tuning[J]. ACM Computing Surveys, 56(12) : 1–38.

[122] Dehghani M, Djolonga J, Mustafa B, et al., 2023. Scaling vision transformers to 22 billion parameters[C]. In: International Conference on Machine Learning, pp. 7480–7512.

[123] Amodei D, Olah C, Steinhardt J, et al., 2016. Concrete problems in AI safety[J]. arXiv preprint arXiv:1606.06565.

[124] Goodfellow I J, Shlens J, Szegedy C, 2014. Explaining and harnessing adversarial examples[J]. arXiv preprint arXiv:1412.6572.

[125] Suthers I, Rissik D, Richardson A, 2019. Plankton: A guide to their ecology and monitoring

for water quality[M]. CSIRO Publishing.

[126] Liang S, Li Y, Srikant R, 2018. Enhancing The Reliability of Out-of-distribution Image Detection in Neural Networks[C]. In: International Conference on Learning Representations.

[127] Liu W, Wang X, Owens J, et al., 2020. Energy-based out-of-distribution detection[C]. In: Advances in Neural Information Processing Systems, vol. 33, pp. 21464 – 21475.

[128] Sun Y, Guo C, Li Y, 2021. ReAct: Out-of-distribution detection with rectified activations[C]. In: Advances in Neural Information Processing Systems, vol. 34, pp. 144 – 157.

[129] Sun Y, Li Y, 2022. DiCE: Leveraging sparsification for out-of-distribution detection[C]. In: European Conference on Computer Vision, pp. 691 – 708.

[130] Djurisic A, Bozanic N, Ashok A, et al., 2023. Extremely Simple Activation Shaping for Out-of-Distribution Detection[C]. In: The Eleventh International Conference on Learning Representations.

[131] DeVries T, Taylor G W, 2018. Learning confidence for out-of-distribution detection in neural networks[J]. arXiv preprint arXiv:1802.04865.

[132] Wei H, Xie R, Cheng H, et al., 2022. Mitigating neural network overconfidence with logit normalization[C]. In: Proceedings of the International Conference on Machine Learning, pp. 23631 – 23644.

[133] Sehwag V, Chiang M, Mittal P, 2023. SSD: A Unified Framework for Self-Supervised Outlier Detection[C]. In: International Conference on Learning Representations.

[134] Cortes C, 1995. Support-vector networks[J]. Machine Learning, 20(3) : 273 – 297.

[135] Rumelhart D E, Hinton G E, Williams R J, 1986. Learning representations by back-propagating errors[J]. Nature, 323(6088) : 533 – 536.

[136] Chen T, Guestrin C, 2016. XGBoost: A scalable tree boosting system[C]. In: Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, pp. 785 – 794.

[137] Cover T, Hart P, 1967. Nearest neighbor pattern classification[J]. IEEE Transactions on Information Theory, 13(1) : 21 – 27.

[138] Duda R O, Hart P E, et al., 1973. Pattern Classification and Scene Analysis, vol. 3[M]. New York: Wiley.

[139] Friedman J H, 2001. Greedy function approximation: A gradient boosting machine[J]. Annals of Statistics, pp. 1189 – 1232.

[140] Quinlan J R, 1986. Induction of decision trees[J]. Machine Learning, 1: 81 – 106.

[141] D'souza D, Nussbaum Z, Agarwal C, et al., 2021. A tale of two long tails[J]. arXiv preprint arXiv:2107.13098.

[142] Denker J, LeCun Y, 1990. Transforming neural-net output levels to probability distributions[C]. In: Advances in Neural Information Processing Systems, vol. 3.

[143] Yuksekgonul M, Zhang L, Zou J Y, et al., 2024. Beyond confidence: Reliable models should also consider atypicality[C]. In: Advances in Neural Information Processing Systems, vol. 36.

[144] Eerola T, Batrakhanov D, Barazandeh N V, et al., 2024. Survey of automatic plankton image recognition: Challenges, existing solutions and future perspectives[J]. Artificial Intelligence Review, 57(5) : 114.

[145] Hoppenrath M, Elbrächter M, Drebes G, et al., 2009. Marine phytoplankton[M]. Kleine Senckenberg-Reihe 49: 1 – 264.

[146] Sosa-Trejo D, Bandera A, González M, et al., 2023. Vision-based techniques for automatic marine plankton classification[J]. Artificial Intelligence Review, 56(11) : 12853 – 12884.

[147] Coates A, Ng A Y, 2012. Learning feature representations with k-means[C]. In: Neural Networks: Tricks of the Trade, pages 561 – 580.

[148] Oord A v d, Li Y, Vinyals O, 2018. Representation learning with contrastive predictive coding[J]. arXiv preprint arXiv:1807.03748.

[149] Chen X, Fan H, Girshick R, et al., 2020. Improved Baselines with Momentum Contrastive Learning[J]. arXiv:2003.04297 [cs].

[150] Hénaff O J, Srinivas A, De Fauw J, et al., 2020. Data-efficient image recognition with contrastive predictive coding[C]. In: International Conference on Machine Learning, pp. 4182 – 4192. PMLR.

[151] Zhang X, Tian Y, Huang W, et al., 2022. Hivit: Hierarchical vision transformer meets masked image modeling[J]. arXiv preprint arXiv:2205.14949.

[152] Geifman Y, Uziel G, El-Yaniv R, 2023. Bias-Reduced Uncertainty Estimation for Deep Neural Classifiers[C]. In: International Conference on Learning Representations.

致　谢

时光荏苒，回首论文撰写的历程，感慨万千。值此研究完成之际，谨向所有在此过程中给予我支持与帮助的师长、亲友致以最诚挚的谢意。

首先，衷心感谢我的导师谢传龙教授。从选题的确定、实验框架的设计到论文的修改，您始终以渊博的学识和严谨的治学态度为我指明方向。您对前沿技术的敏锐洞察力与对科研问题的深刻剖析，使我得以突破研究中的瓶颈。您不仅在学术上倾囊相授，更以身作则教会我如何以批判性思维面对挑战。每一次讨论都让我受益匪浅，您的耐心与包容是我科研道路上最坚实的后盾。

同时，在此感谢实习期间的 mentor。在 L2 自动驾驶的实践经历中，您为我提供了宝贵的行业视角与技术指导。从模型部署的优化到领域数据的处理，您以丰富的工程经验帮助我将理论转化为实际应用。您对细节的极致追求与创新精神，让我深刻体会到科研与产业结合的深远意义。这段经历不仅拓宽了我的视野，更让我学会以更务实的态度面对复杂问题。

感谢我的父母与家人。求学路上，你们始终无条件支持我的选择，用理解与鼓励为我筑起温暖的港湾。当我因秋招、论文实验和写作受挫而焦虑时，你们的关怀总能让我重拾信心。你们教会我以乐观的心态面对困难，这份精神力量是我完成研究的最大动力。在此，谨以本文献给默默付出的你们。

最后，感谢哈尔滨工业大学与中国科学院深圳先进技术研究院合作项目组提供宝贵的原位图像数据集，以及 OpenMMLab 社区对于开源框架的建设和维护，并在此向所有参与论文评审与答辩的专家致以敬意，你们的宝贵意见将指引我在科研道路上不断精进。未来，我愿以更饱满的热情投身于人工智能技术的研究中。

2025 年 5 月